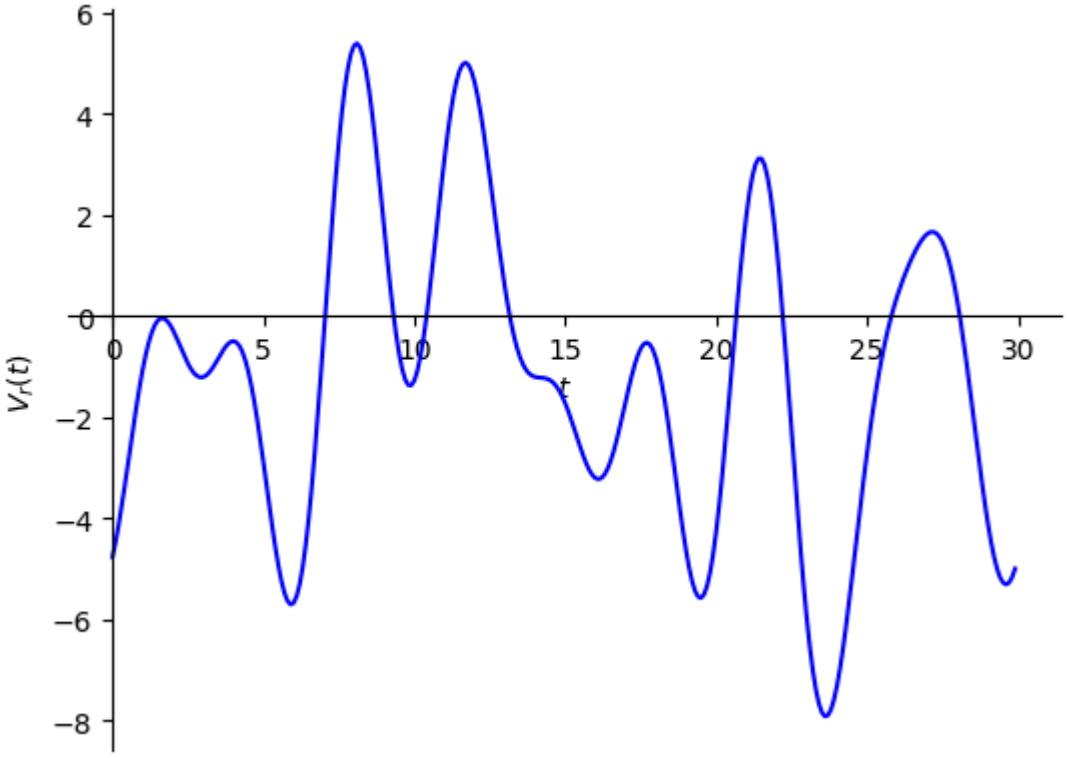
מה זה רעש

לרוב העולם שאנחנו מדמיינים נראה ככה

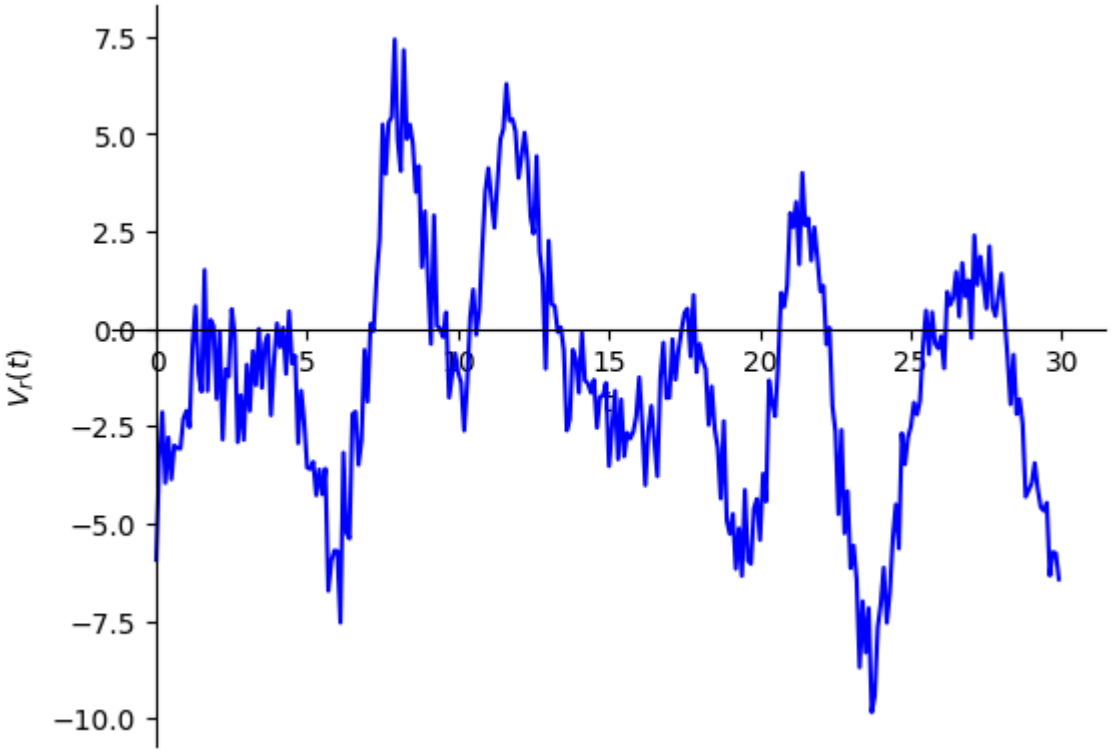
מישהו משדר לי אות ואני קולט אותו באופן הבא:

כשבפועל סיגנל



אף פעם לא נראה ככה אלא יותר ככה:

כלומר תמיד



יהיה לנו בסיגנל שלנו "רעש". חלק לא צפוי שמפריע לנו (לרוב).

רעשים הם אינהרנטים לכל מערכת פיזיקלית. במערכות שיש בהם רכיבים חשמליים תמיד נמצא לפחות שני רעשים:

- רעש טרמי - רעש שנוצר מהתנודות האקראיות של חלקיקים. תנועה של מטענים זה זרם. וזרם מתורגם למתח
- רעש שוט - דומה לרעש קוונטיזציה. נובע מכך שנושאי המטען שלנו (האלקטרונים) הם בדידים. ולכן הזרם הוא בעצם אות מקוונטט

כמובן שיש עוד אינסוף מקורות שאנחנו מתייחסים אליהם או שהם מתנהגים כמו רעש:

- מכסחות דשא
- מזגנים
- האוטובוסים ברחוב מחוץ לדירה שלי
- המון אנשים שמדברים בו זמנית
- מאוורר
- משדרים אחרים
- שבשים של תקשורת

לצורך הדיון שלנו ההבדל בין הפרעה לרעש הוא שנתייחס לרעש כאקראי. כלומר רעש לא ניתן לצפות במדוייק בעוד הפרעה כן.

המודל שלנו יהיה כמעט תמיד שבשלב שבו רעש מתווסף הוא מתווסף לאות כאיבר נוסף כלומר:

$$\underbrace{V_r\left(t\right)}_{\text{בקליטה}} = \underbrace{V_s\left(t\right)}_{\text{אות—נקי}} + \underbrace{n\left(t\right)}_{\text{רעש}}$$

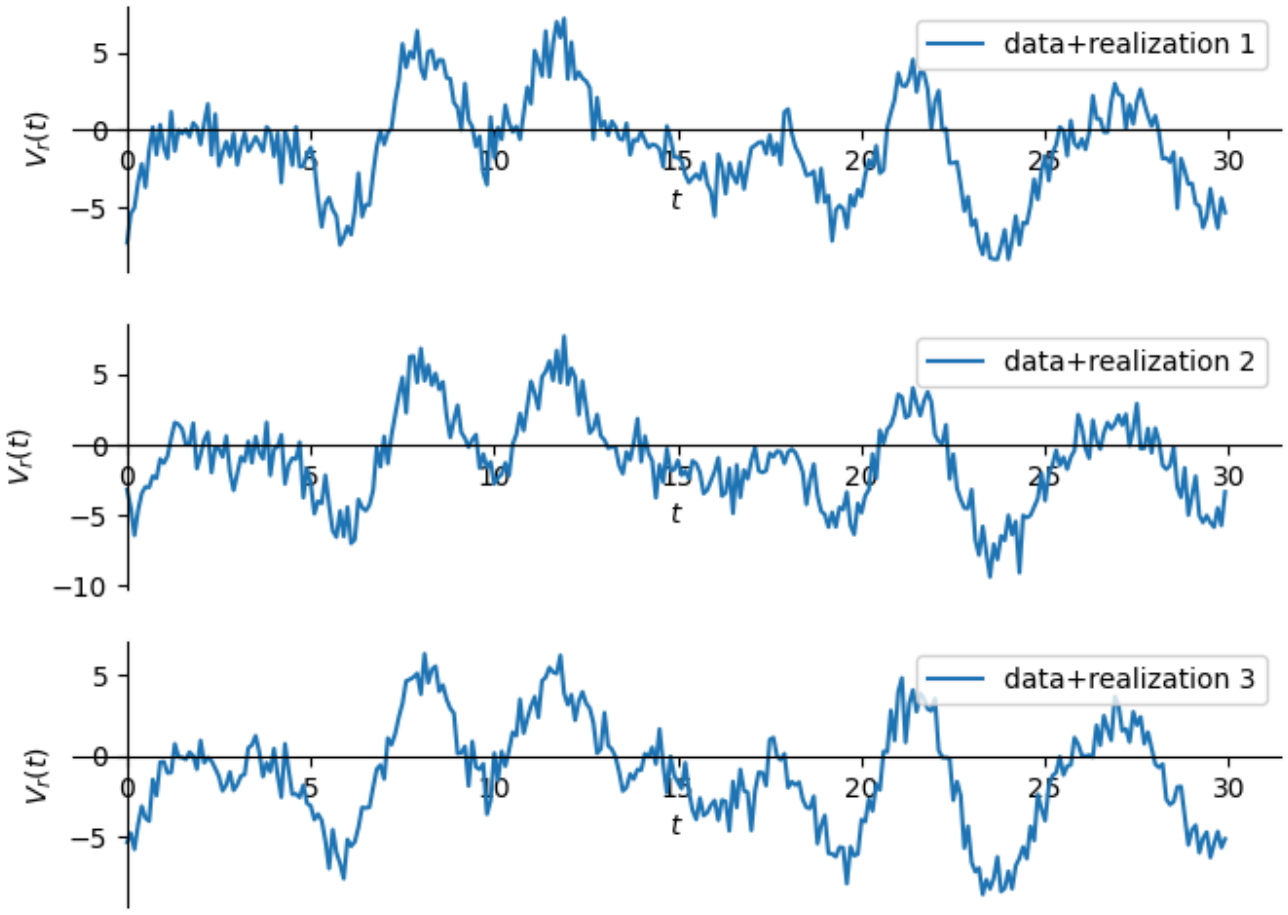
חשוב לשים לב שלדוגמא אוזניות שמבטלות רעשים לא באמת מבטלות רעשים אלא הפרעות. הן מודדות את ההפרעות מהסביבה כל הזמן.

מבחינתנו בשורה התחתונה:

> רעש אינו אות דטרמיניסטי עם נוסחה כמו $\sin\left(\omega_0 t\right)$ אלא הוא **אות אקראי** (כמו הטלת קוביה)

זה אומר שאם נחזור על אותו ניסוי שוב ושוב (נגיד הקלטה של אות) הרעש יהיה שונה כל פעם. הרעש בכל ניסוי נקרא **ריאליזציה**. אוסף כל הניסויים נקרא **אנסמבל**, והוא מגדיר את הסטטסיטיקה של הרעש.

נניח אם היינו מקליטים 3 פעמים את אותו סיגנל היינו מקבלים 3 תוצאות שונות:



חשוב לציין שיש אותות אקראיים שאנחנו לא מתייחסים אליהם כרעש. לדוגמא:

- תנועה של יתושים במרחב
- דעיכה של אטומים רדיואקטיבים
- תנודות של מניות בבורסה
- ירי של נוירונים

באופן כללי הרבה מערכות קשה לנתח באופן מיקרוסקופי ונוכל לעבוד רק עם הסתברויות ולהניח שיש סטטיסטיקה שאנחנו דוגמים ממנה.

אותות אקראיים

Contents

- משתנה אקראי
- סטציונריות הגדרה מחמירה
- ארגודיות
- אפיון של האות האקראי
- אוטוקורלציה
- אותות אנרגיה ואותות הספק
- סטציונריות במובן הרחב

אמ;לק

תהליך אקראי (או אות אקראי) הוא אוסף משתנים מקריים. יכולה להיות לכולם את אותה התפלגות או לא ויכולות גם להיות תלויות בינהם.

שתי הנחות שאנחנו הולכים להניח על כל אות מסוף פרק זה והלאה:

1. סטציונריות במובן הרחב

נאמר שאות אקראי $x(t)$ הוא סטציונרי במובן הרחב אם:

1. הממוצע שלו לאורך זמן קבוע - $\mu_x(t) = \mathbb{E}[x(t)] = \underbrace{\mu_x}_{\text{קבוע}}$
2. האוטוקורלציה שלו תלויה רק בהפרשי זמן - $R_x(t_i, t_j) = R_x(t_i - t_j)$

2. ארגודיות

נאמר שאות ארגודי אם **ממוצע לאורך זמן הוא כמו ממוצע של הרבה מדידות חוזרות (ראליזציות)**

כלומר:

$$\mathbb{E}[x(t)] = \langle x(t) \rangle$$

את האוטוקורלציה הגדרנו להיות:

$$R_x(\tau) \equiv \mathbb{E}[x(0) \cdot x^*(\tau)]$$

כלומר כמה האות דומה לעצמו בהזזה של τ. אם אנחנו מניחים ארגודיות וסטציונריות ממש אפשר לחשב אוטוקורלציה כמו "שהיינו רוצים"

$$R_x(\tau) = \lim_{T \to \infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} x(t) x^*(t+\tau) dt$$

ראינו שלוש תכונות חשובות של הקורלציה:

1. **קישור להתפלגות בכל רגע** - $R_x(0) = \sigma_x^2 + \mu_x^2$ כלומר מתארת את הספק האות האקראי בתור חיבור של הממוצע בריבוע וסטיית התקן בריבוע
2. **מקסימום מתקבל ב-0** - $\forall \tau > 0 : |R_x(\tau)| \leq R_x(0)$

3. **סימטרית (יוניטרית)** - $R_x(-\tau) = R_x^*(\tau)$

נתחיל לחקור את היצור המתמטי הזה שנקרא אות אקראי. דרך אחת לא מאוד שימושית לאפיין אותו היא לומר שיש לנו אנסמבל (אינסופי) עם כל האפשרויות השונות לאותות ולכל אחד מהם הסתברות (או צפיפות הסתברות). ממש קשה לעבוד עם אובייקט כזה. והוא מאוד מאוד כללי.

במקום זה נתחיל מלהסתכל על זמן מסויים t_i ולשאול מה הערכים האפשריים של הרעש שם.

משתנה אקראי

אם היינו מבצעים הרבה מאוד ניסויין ומסתכלים רק על הזאות האקראי (הרעש) בזמן t_i היינו מקבלים המון ערכים שונים. נקרא להם $x(t_i)$. זה ממש כמו הטלות של קובייה רק שיש לנו טווח ערכים רציף. נוכל לאפיין את הסטטיסטיקה של הערכים על ידי **פונקציית צפיפות הסתברות**.

באופן כללי ל$x(t_i)$ נקרא משתנה אקראי.

מה זה פונקציית צפיפות הסתברות?

משתנה אקראי X יהיה מאופיין על ידי פונקציית צפיפות הסתברות $p_X(x)$ אשר אומרת מה הסיכוי למדוד את המשתנה האקראי בטווח ערכים מסויים. כלומר:

$$\mathbb{P}(x_1 < X < x_2) = \int_{x_1}^{x_2} p_X(x)dx$$

נדרוש שתי תכונות:

1. חיוביות - $p_X(x) \geq 0$
2. נרמול - $\int_\Omega p_X(x)dx = 1$

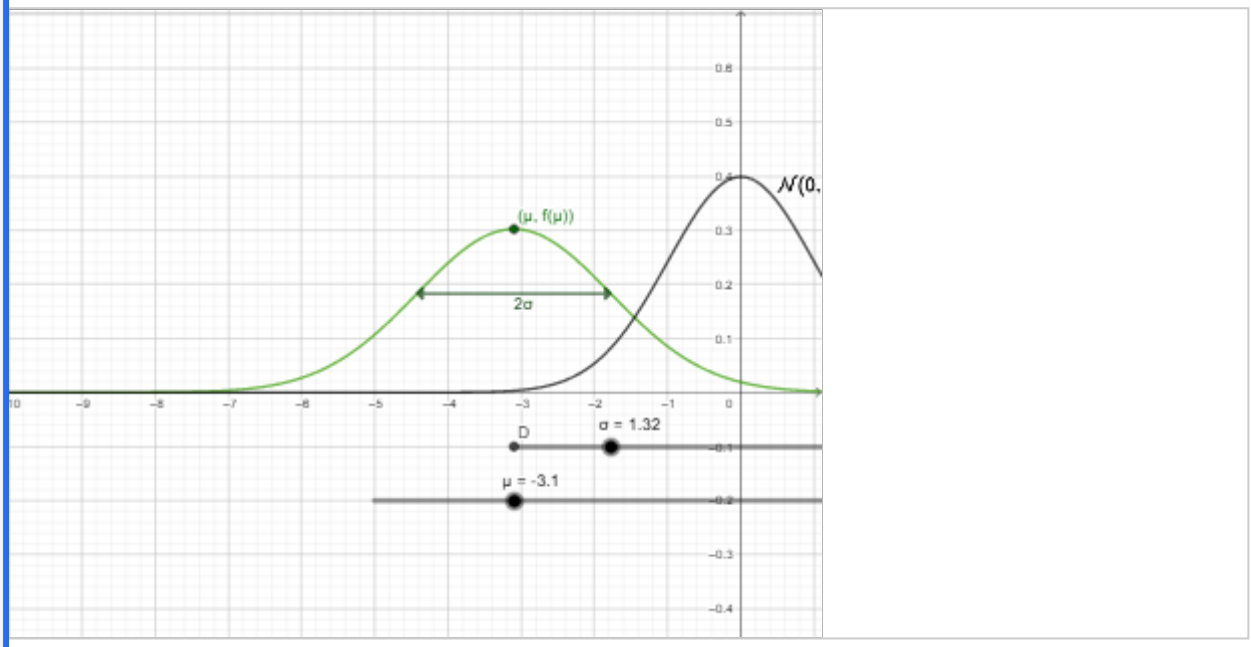
כאשר הכוונה בΩ היא כל תחום הערכים של X. לרוב יהיה $\int_{-\infty}^{\infty} p_X(x)dx = 1$

דוגמא - התפלגות נורמלית

פונקציית צפיפות הסתברות שנעבוד איתה הרבה והיא מאוד מאוד נפוצה היא גאוסיין. (לפעמים נקראת נורמלית)

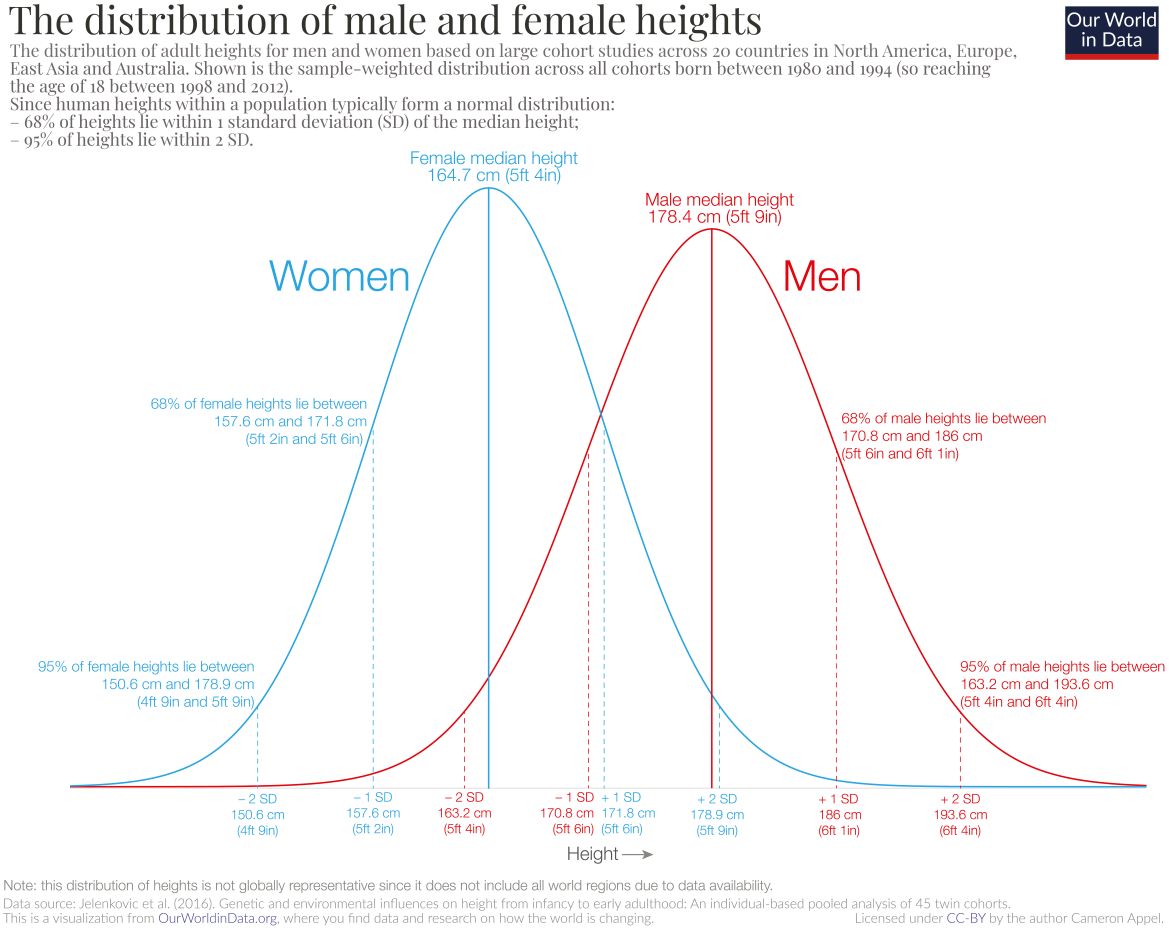
$$p_X(x) = \sqrt{\frac{1}{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

כאשר μ היא הערך הממוצע וσ הסטיית תקן. מוזמנים לשחק עם הערכים כדי לראות אי ך הפונקצייה נראית. את ההתפלגות הנורמלית של ממוצע 0 וסטיית תקן 1 ציירתי בשחור



לפתיחה בחלון נפרד

מה מתפלג ככה? האמת שכמעט הכל (יש לזה סיבות טובות). לדוגמה גובה של אנשים:



מתוך הגרף הזה אתם יכולים לחשב לדוגמה מה הסיכוי שהגובה של גבר או אישה רנדומלים בעולם הם בין 170-175 . זה פשוט לחשב אינטגרל (או לשאול מה השטח מתחת לגרף)

נרצה עכשיו להרחיב את ההגדרה של משתנה אקראי לתהליך אקראי או אות אקראי. נצטרך עכשיו לתת הסתברות לכל אפשרות. כלומר תהיה לנו פונקצייה $\underbrace{p_{x(t)}\left(x_1, x_2, x_3, \ldots; t_1, t_2, t_3, \ldots\right)}_{\text{התפלגות—משותפת}}$ אשר מגדירה מה הסיכוי לאות

מסויים:

$$\mathbb{P}\left(\left(x_1' < x\left(t_1\right) < x_1''\right) \wedge \left(x_2' < x\left(t_2\right) < x_2''\right) \ldots\right) = \int_{x_1'}^{x_1''} \int_{x_2'}^{x_2''} \ldots p_{x(t)}\left(x_1, x_2, \ldots; t_1, t_2, \ldots\right) \ldots dx_1 dx_2 \ldots$$

זה מאוד לא שימושי, בעיקר שהאות שלנו הוא רציף ולא בדיד הרבה פעמים. נניח שתי הגדרות שמאוד יקלו על ההגדרה והניתוח של האות האקראי. הן לא מתקיימות תמיד אבל כן לרוב.

סטציונריות הגדרה מחמירה

נתחיל מהגדרה מחמירה של מה זה אות סטציונרי. נראה קצת דוגמאות וניקח הגדרה פחות מחמירה בהמשך.

נגדיר אות כסטציונרי (במובן הצר) אם פונקציית צפיפות ההסתברות שלו לא משתנה בזמן. כלומר:

$$\forall \tau \in \mathbb{R}, \forall n \in \mathbb{N} : p_{x(t)}\left(x_1, x_2, \ldots, x_n; t_1, t_2, \ldots t_n\right) = p_{x(t)}\left(x_1, x_2, \ldots, x_n; t_1 + \tau, t_2 + \tau, \ldots t_n + \tau\right)$$

ובפרט עבור משתנה זמן בודד:

$$\boxed{\forall \tau \in \mathbb{R} : p_{x(t)}\left(x_1; t_1\right) = p_{x(t)}\left(x_1; t_1 + \tau\right)}$$

מה זה אומר? במילים פשוטות זה אומר שאם תתחילו מדידה של האות בזמן כלשהו למשך זמן כלשהו הסטטיסטיקה לא תהיה תלוייה בזמן התחלת המדידה. שימו לב שזה נכון גם למדידה של מספר אחד ולכן **בפרט** הממוצע וסטיית התקן לא משתנות בזמן. (זאת הולכת להיות ההגדרה שלנו בהמשך + פרט קטן).

דוגמאות לאותות שהם לא סטציונרים:

- הטמפרטורה בחדר הזה - אם תמדדו בלילה או ביום תקבלו סטטיסטיקות שונות מאוד
- הרעש מחוץ לחלון הדירה שלי. במהלך היום יש תחב"צ ובפרט הרעש נמוך יותר בשבתות

נשים לב שזה שיש "שינוי" או אירועי קיצון לא אומר שהאות לא סטציונרי. זה רק אומר שאירועים כאלו הם חלק מהסטטיסטיקה. מה שהופך את הדוגמאות קודם ללא סטציונרים זה שיש "חוקיות" לשינוי של הסטטיסטיקה. לדוגמה בלילה וביום. שימו לב שגם אם לא הייתי יודע שקיימים יום ולילה הייתי יכול לחשב את ממוצע הטמפרטורה לאורך זמן ולראות מגמה מחזורית מובהקת. והסיכוי לקבל מגמה כזו מובהקת במקרה הוא מאוד מאוד נמוך.

דוגמאות לאותות סטציונרים:

- רעש טרמי (בהינתן שהטמפרטורה קבועה) - התפלגות המהירויות של החלקיקים נשארת קבועה אם הטמפרטורה קבועה. ולכן גם הזרמים שהם יוצרים
- רעש שוט (בהנחה שהזרם נשאר קבוע)
- רעש מתפרץ - רעש שקופץ בין שני ערכים כאשר כמות המעברים מתפלגת פואסונית
- תנועה של חלקיק בדיפוזיה

חשוב להדגיש שתהליך אקראי הוא לא תמיד רעש אבל אותנו מעניינים רעשים. תהליך אקראי לדוגמה שאינו רעש הוא ירי של נוירונים במוח שלנו.

ארגודיות

התכונה השנייה שנניח על התהליכים האקראיים שלנו היא קצת יותר קשה לתפיסה. בגדול היא אומרת ש:

> **ממוצע לאורך זמן הוא כמו ממוצע של הרבה מדידות חוזרות (ראליזציות)**

בנוסחה זה אומר ש:

$$\mathbb{E}\left[x\left(t\right)\right]=\left\langle x\left(t\right)\right\rangle$$

מה זה אומר בכלל. אתם רגילים ששני הביטויים האלו הם פשוט סימונים שונים של הממוצע. מה שזה אומר הוא ש:

$$\underbrace{\int_{-\infty}^{\infty}x\cdot\mathbb{P}\left(x\right)dx}_{\mu_x}=\underbrace{\lim_{T\to\infty}\frac{1}{T}\int_{0}^{T}x\left(t\right)dt}_{\left\langle x(t)\right\rangle}$$

כלומר הממוצע של האות הוא גם הממוצע לאורך זמן. (אנחנו נניח שבהגדרה של ארגודיות הממוצע לאורך זמן לא תלוי בזמן ההתחלה, כלומר האות סטציונרי)

איך בכלל שני הדברים האלו יכולים להיות שונים? נשים לב שהם צריכים להיות שווים רק בגבול של זמן ארוך. כלומר גם אם חישוב הממוצע לוקח המון זמן זה לא משנה.

דוגמה שממחישה למה הם יכולים להיות שונים היא הדוגמה הבאה:

נניח שיש לנו 2 קוביות על השולחן. אחת עם 6 פאות ואחת עם 12. כלומר הממוצע של הראשונה הוא 3.5 ושל השנייה הוא 6.5. התהליך האקראי הוא לקחת קוביה אקראית ולזרוק אותה אינסוף פעמים. המספרים שיוצאים הם התהליך האקראי שלנו. למה זה לא ארגודי?

צריך להבין מה הממוצע של התהליך. הממוצע מוגדר על הרבה חזרות של התהליך. כאשר בחצי מהפעמים נבחר את הקוביה הראשונה ובחצי את הקובייה השנייה. הממוצע יצא לנו $\frac{3.5+6.5}{2}=5$ אבל אם ניקח ניסוי אחד לאורך הרבה זמן ונחשב את הממוצע יצא לנו או 3.5 או 6.5.

המסקנה היא:

> אם אנחנו התהליך יכול להיות תהליך שונה בכל פעם וזה נקבע בהתחלה, אז כנראה שהוא לא ארגודי

יכולות להיות הרבה דוגמאות לזה. אבל תנסו לדמיין שאנחנו מודדים בעזרת מכשיר מדידה רעש אבל יכול להיות שיש פגם במכשיר. אז מה שבאמת צריך לעשות הוא לדגום בעזרת הרבה מכשירים.

או יש פאזה התחלתית בדוגם שיכולה להגביר או להחליש את הרעש והיא נקבעת על פי זמן ההדלקה של המכשיר אז אנחנו יכולים להיות בבעיה.

יש עוד דוגמאות מעניינות ממש בפיזיקה אבל לא ניכנס לזה כאן.

למה ארגודיות חשובה לנו בכלל? היינו רוצים לומר שאם הממוצע של האות לא תלוי בזמן (סטציונריות) אז ה מספיק. הבעיה היא שלרוב במדידה אמיתית תהיה לנו רק ריאליזציה אחת של הרעש. ולכן אם נחשוב שהממוצע של הרעש הוא הממוצע מהתכונה הסטציונרית נוכל לטעות ולחשוב שזה הממוצע בכל קטע מספיק ארוך של זמן.

לרוב נניח שאות גם ארגודי בסטיית התקן שלו ובפונקציית האוטוקורלציה שלו (עוד על זה בהמשך).

אפיון של האות האקראי

בהינתן שיש לנו דגימה של האות האקראי והוא סטציונרי וארגודי נוכל להתחיל לחשב תכונות שלו:

- ממוצע - $\mu_x = \int_{-\infty}^{\infty} x \cdot \mathbb{P}(x) dx = \lim_{T\to\infty} \frac{1}{T} \int_0^T x(t) dt$
- סטיית תקן - **כמה אנחנו רחוקים מהממוצע בממוצע**

איך נחשב?

$$\sigma_x^2 = \mathbb{E}\left[(x(t) - \mu_x)^2\right] = \mathbb{E}\left[x(t)^2 - 2\mu_x x(t) + \mu_x^2\right] = \mathbb{E}\left[x(t)^2\right] - 2\mu_x \mathbb{E}\left[x(t)\right] + \mu_x^2$$

$$= \mathbb{E}\left[x(t)^2\right] - 2\mu_x^2 + \mu_x^2 = \mathbb{E}\left[x(t)^2\right] - \mu_x^2 = \left\langle x(t)^2 \right\rangle - \mu_x^2 = \lim_{T\to\infty} \frac{1}{T} \int_0^T x(t)^2 dt - \left(\lim_{T\to\infty} \frac{1}{T} \int_0^T x(t) dt \right)^2$$

נשים לב שבמקרה שלנו האות $x(t)^2$ הוא לרוב בעל משמעות של הספק (אם האות שלנו הוא אמפליטודה של גל) ולכן אפשר לחשוב על $\left\langle x(t)^2 \right\rangle$ בתור ההספק הממוצע נקבל מסקנה חמודה:

> באות בעל ממוצע 0 ($\mu_x = 0$) סטיית התקן פרופורציונלית להספק הממוצע $\sigma_x^2 \propto \langle P_x \rangle$

כלומר שסטיית התקן של רעש (שלרוב ההמוצע שלו הוא באמת 0) היא סופר חשובה לחישובי SNR

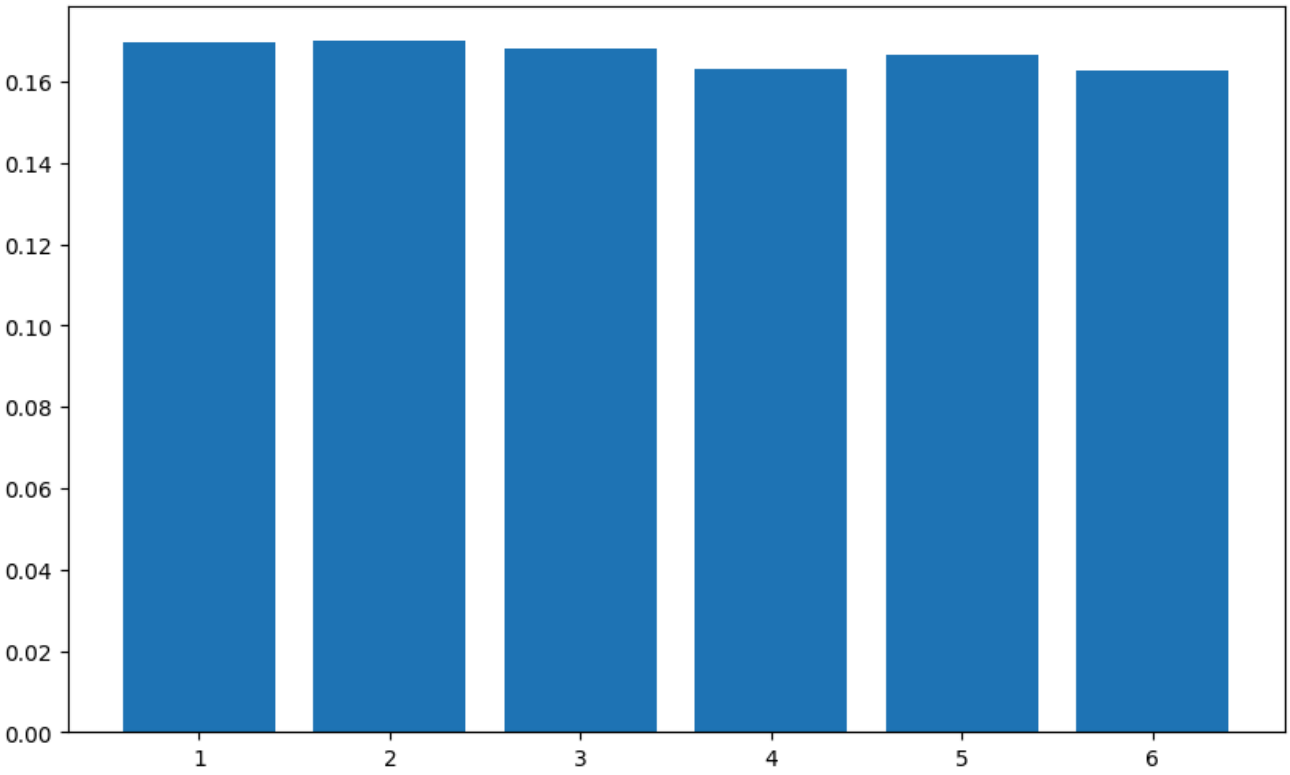
אוטוקורלציה

יש לנו פיסה אחת שחסרה בפאזל. הבנו שאפשר לאפיין את האות האקראי בכל נקודת זמן עם פונקצייה p_x אשר לא תלוייה בזמן אבל מה הקשר בין הרעש בזמנים שונים? לדוגמה מה אם הייתי אומר לכם שאני מטיל קובייה אבל כל פעם אני לא מאפשר להטלה הקודמת לחזור על עצמה. האם זה משנה את סטטיסטיקת ההטלות? התשובה היא שברור שלא. נקבל התפלגות אחידה עבור כל אחת מההטלות (עם הרבה חזרות על הניסוי) מוזמנים לדוגמה להסתכל על הקוד הבא:

```
import matplotlib.pyplot as plt
import numpy as np
def get_die_tosses_non_repeate(N, seed=None):
    rng = np.random.default_rng(seed)
    die_tosses = [rng.integers(1, 7)]
    for i in range(1, N):
        # toss a die 1-5 and when the result is greater than the previous toss, add 1
        # this way we get a random toss 1-6 that can't be the same as the previous toss
        current_toss = rng.integers(1, 6)
        if current_toss >= die_tosses[-1]:
            current_toss+=1
        die_tosses.append(current_toss)
    return np.array(die_tosses)

N = 10
num_of_experiments = 10000
all_tosses = []
for i in range(num_of_experiments):
    die_tosses = get_die_tosses_non_repeate(N)
    all_tosses.append(die_tosses)
all_tosses = np.array(all_tosses)
plt.figure(figsize=(10, 6))
plt.hist(all_tosses[:,-1],bins=np.linspace(0.5, 6.5, 7), rwidth=0.8, density=True)
```

שימו לב שאנחנו כל פעם זורקים את הקובייה 10 פעמים כאשר שתי זריקות עוקבות לא יכולות להיות זהות. ואכן נראה שההתפלגות של הקובייה נראית כמו קובייה רגילה. נוכל לקחת היסטוגרמה של הזריקה העשירית ולראות שההתפלגות אכן אחידה:



באופן כללי אני מאוד ממליץ לתכנת לעצמכם דוגמאות קטנות של כל מיני תהליכים אקראיים. זה מאוד עוזר להבין מה הולך ולמה מתכננים בכל מיני מדדים.

אז איך נאפיין את הקשר בין שני משתנים? נהוג לאפיין בצורה הפשוטה ביותר שניתן לחשוב עליה. בעזרת $Cov\left(x_i,x_j\right)$ מה זה COV? ההגדרה היא:

$$Cov\left(x_i,x_j\right)=\mathbb{E}\left[\left(x_i-\mu_{x_i}\right)\left(x_j-\mu_{x_j}\right)^*\right]$$

> אני אגדיר את כל ההגדרות למשתנים אקראיים מרוכבים. אם עובדים עם משתנים אקראיים ממשיים אפשר פשוט להתעלם מכל הפעולות של הצמדה

במילים: כמה בבמוצע סטייה של אחד מהמשתנים מהממוצע **מתואמת** עם סטייה של המשתנה השני

נשים לב שאם אנחנו עובדים עם אות שהממוצע שלו הוא תמיד 0 $\mu_x=0$ אז נקבל:

$$\boxed{Cov\left(x_i,x_j\right)=\mathbb{E}\left[x_i\cdot x_j^*\right]}$$

בהנחה שהתהליך שלנו הוא סטציונרי נוכל לרשום:

$$Cov\left(x\left(t_i\right),x\left(t_j\right)\right)=\mathbb{E}\left[x\left(t_i\right)\cdot x^*\left(t_j\right)\right]=\mathbb{E}\left[x\left(0\right)\cdot x^*\left(t_j-t_i\right)\right]\underbrace{=}_{\tau=t_j-t_i}\mathbb{E}\left[x\left(0\right)\cdot x^*\left(\tau\right)\right]$$

התוצאה תלויה במשתנה בודד τ ויש לה סימון מיוחד (ושם):

$$R_x\left(\tau\right)\equiv\mathbb{E}\left[x\left(0\right)\cdot x^*\left(\tau\right)\right]$$

הפונקציה הזו נקראת האוטוקורלציה של האות והיא מדד של כמה האות ״דומה״ לעצמו בהזזה של τ.

נשים לב שבאופן כללי לרוב מגדירים אוטוקורלציה כ-$R_x\left(t_1,t_2\right)\equiv\mathbb{E}\left[x\left(t_1\right)\cdot x^*\left(t_2\right)\right]$ אבל בגלל הסטציונריות יכולנו להגדיר את זה כפונקציה של משתנה בודד. כלומר:

- אות סטציונרי - $R_x\left(t_1,t_2\right)=R_x\left(0,t_2-t_1\right)=R_x\left(\tau\right)$
- אות סטציונרי עם תוחלת 0 - $R_x\left(\tau\right)=\mathbb{E}\left[x\left(0\right)\cdot x^*\left(\tau\right)\right]=Cov\left(x\left(0\right),x\left(\tau\right)\right)$

> מסקנה: האוטוקורלציה היא פונקציה של הפרשי זמנים $\tau=t_j-t_i$

תכונות חשובות:

- עבור אות ממשי - $R_x\left(0\right)=\mathbb{E}\left[x\left(0\right)\cdot x^*\left(0\right)\right]\underbrace{=}_{\text{ממשי}}\mathbb{E}\left[\left(x\left(0\right)\right)^2\right]=\sigma_x^2$
- סימטריות - $R_x\left(-\tau\right)=\mathbb{E}\left[x\left(0\right)\cdot x^*\left(-\tau\right)\right]=\mathbb{E}\left[x\left(\tau\right)\cdot x^*\left(0\right)\right]=\mathbb{E}\left[x\left(0\right)\cdot x^*(\tau)^*\right]=R_x^*\left(\tau\right)$

נשים לב שאם האות סטציונרי אז נוכל לרשום כי $\forall t: R_x(0) = \mathbb{E}\left[|x(t)|^2\right] \in \mathbb{R}$

האם יתכן מצב בו $|R_x(\tau > 0)| > R_x(0)$ התשובה היא לא:

$$|R_x(\tau > 0)| = |\mathbb{E}[x(0) \cdot x^*(\tau)]| \leq max(|\mathbb{E}[x(0) \cdot x^*(0)]|, |\mathbb{E}[x(\tau) \cdot x^*(\tau)]|) = max(R_x(0), R_x$$

> האות הכי דומה לעצמו כשלא מזיזים אותו. כלומר $\forall \tau > 0: |R_x(\tau)| \leq R_x(0)$
>
> הרבה פעמים מה שנעשה הוא לצייר את הפונקצייה של האוטוקורלציה המנורמלת כלומר $\frac{R_x(\tau)}{R_x(0)}$

דוגמא - רעש טלגרף (מערכת שני מצבים)

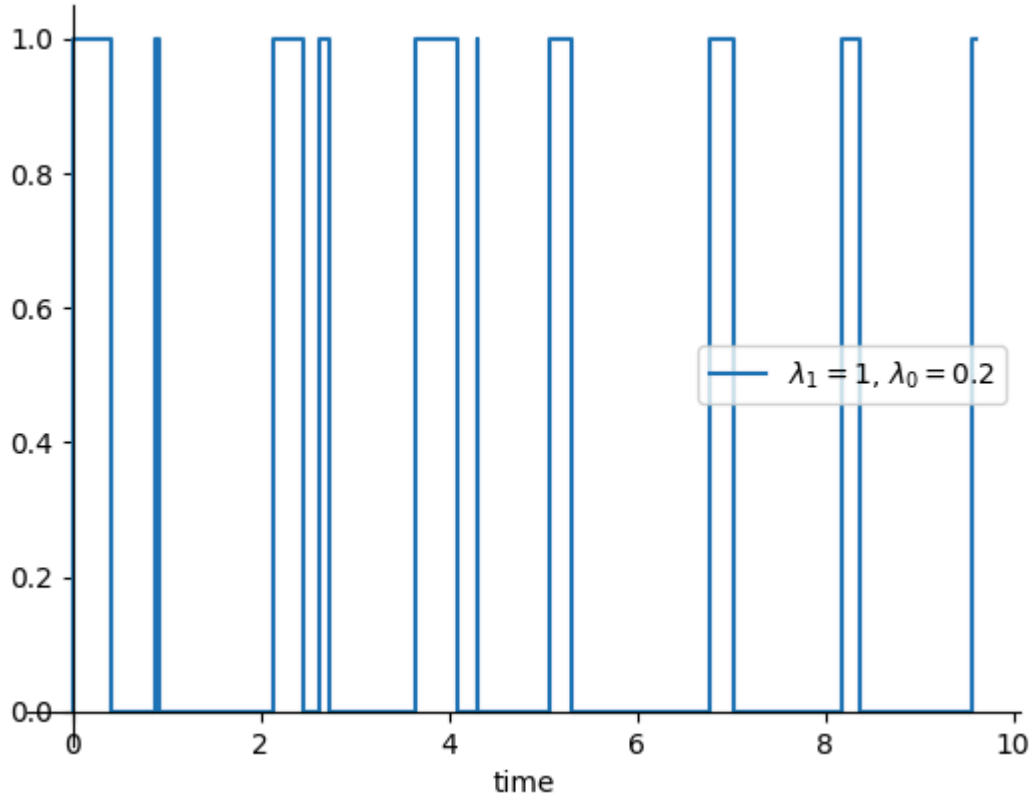
ניקח את המערכת הכי פשוטה שאנחנו יכולים לחשוב עליה (כמעט). נניח שיש לנו שני מצבים. 0,1 נגדיר התפלגות זמני מעבר. זה אומר שאם עכשיו עברתי למצב 1 מה הזמן שאני אשאר שם לפני אני אעבור למצב 0 ואותו הדבר בהינתן שעברתי למצב 0 כמה זמן אשאר שם לפני שאעבור למצב 1.

נגדיר:

$$\tau_{0\to 1}\sim \exp\left(\lambda_0\right)=\begin{cases}\lambda_0 e^{-\lambda_0 t} & t\geq 0\\ 0 & t<0\end{cases}$$

$$\tau_{1\to 0}\sim \exp\left(\lambda_1\right)=\begin{cases}\lambda_1 e^{-\lambda_1 t} & t\geq 0\\ 0 & t<0\end{cases}$$

איך נראה ריאליזציה של תהליך כזה?



אז נרצה לחשב את האוטוקורלציה של האות. נזכור שהאוטוקורלציה היא פונקציה של הפרשי זמן נחשב את האוטוקורלציה בצורה של סיכוי מותנה:

$$\mathbb{E}\left[x\left(t\right)\cdot x\left(0\right)\right]=\mathbb{E}\left[x\left(t\right)\cdot x\left(0\right)|x\left(0\right)=1\right]\cdot\mathbb{P}\left(x\left(0\right)=1\right)+\underbrace{\mathbb{E}\left[x\left(t\right)\cdot x\left(0\right)|x\left(0\right)=0\right]}_{0}\cdot\mathbb{P}$$

$$= \mathbb{E}\left[x\left(t\right) \cdot x\left(0\right) | x\left(0\right) = 1\right] \cdot \mathbb{P}\left(x\left(0\right) = 1\right)$$

נסתכל קודם על הביטוי $\mathbb{E}\left[x\left(t\right) \cdot x\left(0\right) | x\left(0\right) = 1\right]$:

$$\mathbb{E}\left[x\left(t\right) \cdot x\left(0\right) | x\left(0\right) = 1\right] = 1 \cdot \mathbb{P}\left(x\left(t\right) = 1 | x\left(0\right) = 1\right) + 0 \cdot \mathbb{P}\left(x\left(t\right) = 0 | x\left(0\right) = 1\right) = \mathbb{P}\left($$

אז אנחנו צריכים לדעת מה הסיכוי להיות במצב של 1 בזמן t בהינתן שבזמן $t = 0$ התחלנו ב-0.
התשובה לזה מערבת קצת מתמטיקה ויוצא בסוף ש:

$$\mathbb{P}\left(x\left(t\right) = 1 | x\left(0\right) = 1\right) = \frac{\lambda_0 + \lambda_1 e^{-\left(\lambda_0 + \lambda_1\right)t}}{\lambda_0 + \lambda_1}$$

נשים לב שבזמנים קטנים הסיכוי להישאר ב-1 הוא גבוה ושואף ל1 כמו שהיינו מצפים. מצד שני הסיכוי באינסוף לא שואף ל-0 אלא למספר קבוע:

$$\lim_{t \to \infty} \mathbb{P}\left(x\left(t\right) = 1 | x\left(0\right) = 1\right) = \frac{\lambda_0}{\lambda_0 + \lambda_1}$$

מסתבר שהמספר שאם מניחים שהתחלנו לצפות בתהליך בזמן אקראי כלשהו זה גם הסיבוי שהמצב שאנחנו צופים בו יהיה 1 משום שהסיכוי הזה לא תלוי במצב ההתחלתי. לא נחשב כאן אבל הטענה היא ש-

$$\lim_{t \to \infty} \mathbb{P}\left(x\left(t\right) = 1 | x\left(0\right) = 1\right) = \lim_{t \to \infty} \mathbb{P}\left(x\left(t\right) = 1 | x\left(0\right) = 0\right) = \frac{\lambda_0}{\lambda_0 + \lambda_1}$$

נשים לב שזה מסתדר לנו. אם λ_0 גדול זה אומר שאנחנו קופצים מהר החוצה ממצב 0 ולכן נמצאים יותר במצב 1.

נקבל לבסוף כי:

$$\mathbb{E}\left[x\left(t\right) \cdot x\left(0\right)\right] = \underbrace{\frac{\lambda_0 + \lambda_1 e^{-\left(\lambda_0 + \lambda_1\right)t}}{\lambda_0 + \lambda_1}}_{\mathbb{E}\left[x\left(t\right) \cdot x\left(0\right) | x\left(0\right) = 1\right]} \cdot \underbrace{\frac{\lambda_0}{\lambda_0 + \lambda_1}}_{\mathbb{P}\left(x\left(0\right) = 1\right)}$$

כלומר:

$$\boxed{R_x\left(\tau\right) = \mathbb{E}\left[x\left(\tau\right) \cdot x\left(0\right)\right] = \frac{\lambda_0^2 + \lambda_1 \lambda_0 e^{-\left(\lambda_0 + \lambda_1\right)\left|\tau\right|}}{\left(\lambda_0 + \lambda_1\right)^2}}$$

הערך המוחלט הוא בגלל שאנחנו תלויים רק בהפרש הזמנים בערך מוחלט.

מה עם הממוצע לאורך זמן?

$$\mathbb{E}\left[x\left(t\right)\right]=1\cdot\mathbb{P}\left(x\left(t\right)=1\right)+0\cdot\mathbb{P}\left(x\left(0\right)=0\right)$$

ולכן:

$$\boxed{\mu_x=\frac{\lambda_0}{\lambda_0+\lambda_1}}$$

נשים לב שעבור הפרש זמנים מאוד גדול האוטוקורלציה היא:

$$\lim_{\tau\to\infty}R_x\left(\tau\right)=\left(\frac{\lambda_0}{\lambda_0+\lambda_1}\right)^2=\mu_x^2$$

נסרטט:



לפתיחה בחלון נפרד

מה ההתפלגות של התהליך שלנו בכל זמן נתון? נשים לב שכאן אנחנו יכולים להיות רק בשני מצבין ולא באינסוף ולכן לא נצטרך PDF אלא פשוט וקטור שאומר מה הסיכוי להיות בכל מצב. במקרה שלנו:

$$\vec{p}=\begin{pmatrix}\mathbb{P}\left(x\left(t\right)=0\right)\\\mathbb{P}\left(x\left(t\right)=1\right)\end{pmatrix}=\begin{pmatrix}\frac{\lambda_1}{\lambda_0+\lambda_1}\\\frac{\lambda_0}{\lambda_0+\lambda_1}\end{pmatrix}$$

יש לנו את כל מה שאנחנו צריכים :)

אוטוקורלציה עבור אותות לא אקראיים

המדד של אוטוקורלציה כל כך שימושי שאפשר להשתמש בו גם עבור **אותות לא אקראיים** לדוגמא:

$$x\left(t\right)=A\sin\left(\omega t+\phi_0\right)$$

באותות לא אקראיים לא נוכל להשתמש ב-$R_x\left(\tau\right)\equiv\mathbb{E}\left[x\left(0\right)\cdot x^*\left(\tau\right)\right]$ אלא נשתמש ב-
$R_x\left(\tau\right)\equiv\left\langle x\left(0\right)\cdot x^*\left(\tau\right)\right\rangle$ אז נרשום לפי ההגדרה:

$$R_x\left(\tau\right)=\left\langle x\left(t\right),x^*\left(t+\tau\right)\right\rangle\underbrace{=}_{T=\frac{2\pi}{\omega}}\frac{1}{T}\int_0^T\left(A\sin\left(\omega t+\phi_0\right)\right)\left(A\sin\left(\omega\left(t+\tau\right)+\phi_0\right)\right)dt=$$

$$=\frac{A^2}{T}\int_0^T\left(\sin\left(\omega t+\phi_0\right)\right)\left(\sin\left(\omega t+\phi_0\right)\cos\left(\omega\tau\right)+\cos\left(\omega t+\phi_0\right)\sin\left(\omega\tau\right)\right)dt$$

$$=\frac{A^2\cos\left(\omega\tau\right)}{T}\underbrace{\int_0^T\sin^2\left(\omega t+\phi_0\right)dt}_{\frac{T}{2}}+\frac{A^2\sin\left(\omega\tau\right)}{T}\underbrace{\int_0^T\frac{1}{2}\sin\left(2\omega t+2\phi_0\right)dt}_{0}$$

$$=\frac{A^2\cos\left(\omega\tau\right)}{2}$$

אותות אנרגיה ואותות הספק

עד עכשיו קצת התחמקנו מנקודה עדינה. שאתם עשויים להיתקל בה יחסית הרבה. אנחנו יכולים לדבר על שני סוגים של אותות:

- **אותות הספק** - יש להם הספק קבוע בזמן ואנרגיה אינסופית (כי הם על זמן אינסופי)
  - רעש סטציונרי הוא אות הספק משום שההספק פרופורציונלי לסטיית התקן שהיא קבוע
  - גל סינוס מחזורי הוא בעל הספק ממוצע קבוע בכל זמן מחזור ואנרגיה אינסופית
- **אותות אנרגיה** - יש להם אנרגיה סופית
  - פולס מלבני הוא בעל אנרגיה סופית
  - פולס גאוסייני הוא בעל אנרגיה סופית למרות שהוא לא סופי בזמן

כל מה שאנחנו צריכים לשים לב אליו זה להכפלה של $\frac{1}{T}$ כאשר מחשבים את האוטוקורלציה באופן מפורש מתמטי:

- אותות הספק - $R_x(\tau) = \langle x(t), x^*(t+\tau) \rangle = \lim_{T\to\infty} \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} x(t) x^*(t+\tau) dt$
- אותות אנרגיה - $R_x(\tau) = \langle x(t), x^*(t+\tau) \rangle = \lim_{T\to\infty} \int_{-\frac{T}{2}}^{\frac{T}{2}} x(t) x^*(t+\tau) dt$

סטציונריות במובן הרחב

נחזור עכשיו להגדרה של סטציונריות ונהפוך אותה למקלה יותר. הרבה פעמים אנחנו מקבלים דגימות מאות מסויים (לפעמים אפילו דגימה אחת ארוכה) ואין לנו דרך לדעת אם באמת ה-PDF של האות בכל זמן הוא זהה. מה שאנחנו כן יכולים לחשב בקלות הוא ממוצע רץ ואוטוקורלצייה עם זמני התחלה שונים כלומר את $R_x(t, t+\tau) \approx \frac{1}{T} \int_t^{t+T} x(t') x(t'+\tau) dt'$ ולראות אם התוצאה תלוייה רק בτ

עבור תהליך ארגודי נוכל לומר כי:

1. $\langle x(t_i) \rangle = \underbrace{\mu_x}_{\text{קבוע}} \Rightarrow \boxed{\mathbb{E}[x(t_i)] = \underbrace{\mu_x}_{\text{קבוע}}}$
2. $\langle x(t_i) \cdot x^*(t_j) \rangle = \langle x(0) \cdot x^*(t_j - t_i) \rangle \Rightarrow \boxed{R_x(t_i, t_j) = R_x(t_j - t_i)}$

כלומר נוכל לבדוק את שתי התכונות האלו שהן חשובות לנו. נתן שם מיוחד לאות שמקיים את שתי התכונות הללו. נקרא לו סטציונרי במובן הרחב

סטציונריות במובן הרחב

נאמר שאות אקראי $x(t)$ הוא סטציונרי במובן הרחב אם:

1. הממוצע שלו לאורך זמן קבוע - $\mu_x(t) = \mathbb{E}[x(t)] = \underbrace{\mu_x}_{\text{קבוע}}$
2. האוטוקורלציה שלו תלויה רק בהפרשי זמן - $R_x(t_i, t_j) = R_x(t_i - t_j)$

זה אומר שגם $Cov(x(t_i), x(t_j))$ הוא פונקציה רק של הפרשי זמנים:

$$Cov(x(t_i), x(t_j)) = \mathbb{E}\left[(x(t_i) - \mu_x)(x(t_j) - \mu_x)^*\right] = \mathbb{E}[x(t_i), x^*(t_j)] - \mu_x^2 = R_x(t_i -$$

ובפרט סטיית התקן קבועה בזמן:

$$\sigma_x(t) = \sqrt{Cov(x(t), x(t))} = R_x(0) - \mu_x^2 = \underbrace{\sigma_x}_{\text{קבוע}}$$

כל האותות שנעבוד איתם מהנקודה הזו והלאה (אלא אם צויין אחרת) הם ארגודים וסטציונרים במובן הרחב.

הסטציונריות במובן הרחב חשובה לנו על מנת לאפיין את התכונות של האות

הארגודיות חשובה לנו כדי שנוכל לקבוע את התכונות של האות באמצעות דגימה ארוכה של האות ולא בעזרת המון ריאליזציות שונות

נשים לב שסטציונריות במובן הרחב לא מחייבת שכל המשתנים האקראיים של האות יתפלגו בדיוק באותה צורה בכל זמן. וגם לא שההתפלגות המשותפת תהיה בדיוק זהה בזמנים שונים. זאת הגדרה הרבה יותר מקלה אבל גם מאוד מאוד שימושית. אנחנו נראה בהמשך איך פונקציית האוטוקורלציה משחקת תפקיד מרכזי בניתוח של רעשים בתדר.

נסכם:

אות סטציונרי במובן הרחב מאופיין על ידי:

- ממוצע - μ_x
- פונקציית אוטוקורלציה - $R_x\left(\tau\right)$

אם האות ארגודי ניתן לחשב את שני הגדלים האלו:

- ממוצע - $\mu_x\left(t\right)=\lim_{T\to\infty}\frac{1}{T}\int_{-\frac{T}{2}}^{\frac{T}{2}}x\left(t\right)dt$
- אוטוקורלציה - $R_x\left(\tau\right)=\lim_{T\to\infty}\frac{1}{T}\int_{-\frac{T}{2}}^{\frac{T}{2}}x\left(t\right)x^*\left(t+\tau\right)dt$

עכשיו כשיש לנו תשתית לדבר על אותות אקראיים נתחיל להבין איך זה קשור לאותות ולתדרים. איך זה מתקשר לקליטה של אותות ופענוח.

רעש במרחב התדר

Contents

- PSD
- Wiener–Khinchin theorem
- סינון רעש
- חיבור רעשים
- הספק תדרי

ראינו כבר עד עכשיו שאותות יותר נוח לנתח במרחב התדר. בעיקר כשיש לנו מערכת לינארית שהאות עובר דרכה.

אני מזכיר שמעכשיו האות שלנו הולך להיות מהצורה:

$$x\left(t\right)=\underbrace{s\left(t\right)}_{\text{אות}}+\underbrace{n\left(t\right)}_{\text{רעש}}$$

היינו רוצים לכתוב:

$$\tilde{X}\left(\omega\right)=\tilde{S}\left(\omega\right)+\tilde{N}\left(\omega\right)$$

וזה אכן נכון אבל נשים לב שאין לנו נוסחה ל-$n\left(t\right)$ כך שאנחנו לא באמת יכולים לחשב את $\tilde{N}\left(\omega\right)$. עבור כל ריאליזציה נקבל משהו שונה.

מה כן יש לנו בכלל? אם נניח שהאות הוא WSS (wide sense stationary - סטציונרי במובן הרחב) אז יש לנו שתי תכונות של האות שאנחנו יכולים לעבוד איתן:

- ממוצע - μ_x
- פונקציית אוטוקורלציה - $R_x\left(\tau\right)$

נשים לב שהאוטוקורלציה של האות מאוד מזכירה לנו קונבולוציה רק שלא הופכים את אחת הפונקציות:

$$R_x\left(\tau\right)=\int_{-\infty}^{\infty}x\left(t\right)x^*\left(t+\tau\right)=\int_{-\infty}^{\infty}x\left(t\right)x^*\left(\tau-\left(-t\right)\right)dt=x\left(t\right)*x\left(-t\right)$$

$$\tilde{S}_{xx}(\omega) = \mathcal{F}[R_x(\tau)] = \mathcal{F}[x(t) * x(-t)] = \sqrt{2\pi}\tilde{X}(\omega) \cdot \tilde{X}^*(\omega) = \sqrt{2\pi}\left|\tilde{X}(\omega)\right|^2$$

PSD

נצא מתוך האינטואיציה הזו ונתן שם לגודל $\tilde{S}_{xx}(\omega)$. נקרא לו Power Spectral Density או בקיצור PSD הוא הולך לומר לנו איך האנרגיה של האות האקראי שלנו מתחלקת בין תדרים שונים

אפשר לבדוק יחידות ולראות שה-PSD נמדד ב-$\frac{W}{Hz}$ כלומר הספק לפורסת תדר ולכן זה נקרא **צפיפות הספק ספקטרלית**

בהמשך נעשה את החיבור לפורייה של הריאליזציה $\tilde{X}(\omega)$

דוגמא - רעש לבן

ניקח את הדוגמה הכי בסיסית שאנחנו יכולים לחשוב עליה. אוטוקורלציה של 0 בכל זמן חוץ מהראשית וממוצע 0:

$$R_x(\tau) = \sigma^2\delta(\tau)$$

$$\mu_x = 0$$

יש כאן נקודה עדינה. אם האוטוקורלציה היא אינסוף ב$\tau = 0$ איך נראה המשתנה המקרי? אני לא אכנס לזה כאן. מוזמנים לקרוא את הבלוג הזה לדוגמא ואת הספר שהוא מפנה אליו בכל מקרה נמשיך עם זה ש שהאוטוקורלציה שלנו מוגדרת ואנחנו לא מפחדים!

איך יראה ה-PSD $\tilde{S}_{xx}(\omega)$?

זה כבר פשוט, צריך לעשות פורייה לדלתא ומקבלים:

$$\tilde{S}_{xx}(\omega) = \frac{\sigma^2}{\sqrt{2\pi}}$$

כלומר פונקציה קבועה!

> ה-PSD של רעש לבן הוא קבוע (לכן הוא נקרא לבן - הוא מכיל את כל התדרים)

Warning

אנחנו הולכים לדבר הרבה בהמשך על מה שנקרא רעש לבן גאוסייני. חשוב לראות שלא הנחנו כלום על ה-PDF של הרעש בכל זמן ומה שהיה חשוב כדי שהוא יהיה לבן זה שהוא יהיה חסר קורלציה.

יכולים להיות רעשים לבנים כל התפלגות שאתם יכולים לחשוב עליה

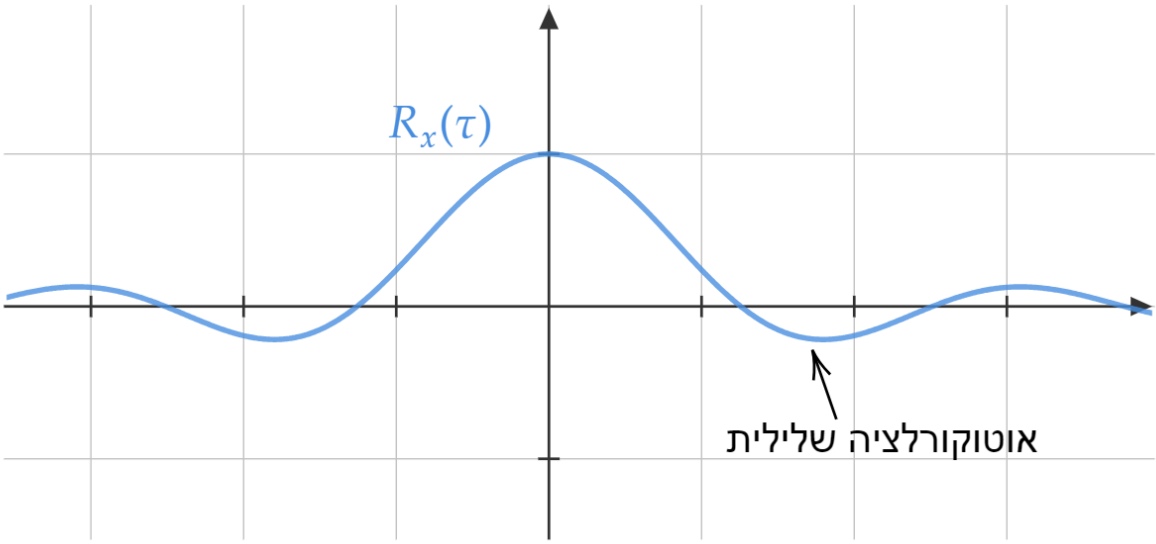
רעש לבן $\iff$ רעש עם אוטוקורלציה של $R_x(\tau)=\sigma^2\delta(\tau)$

דוגמא - רעש לבן בעל רוחב סרט סופי

$$\tilde{S}_{xx}(\omega)=\frac{\sigma^2}{\omega_c\sqrt{2\pi}}Rect\left(\frac{\omega}{\omega_c}\right)$$

ולכן:

$$R_x(\tau)=\sigma^2 sinc\left(\frac{\omega_c}{2\pi}t\right)$$



נשים לב שיש מקומות בהן האוטוקורלציה שלילית! זה לא טעות ולא אותו הדבר כמו קורלציה 0 זה אומר שבממוצע אם הרעש בזמן 0 הוא חיובי אז הרעש בזמן τ הוא שלילי (ולהפך)

Wiener–Khinchin theorem

מה זה בכלל אומר לעשות פורייה ל-$x\left(t\right)$ זה פורייה של אחת הריאליזציות. למה שעבור שתי ריאליזציות שונות לא נקבל תוצאות שונות?

אז התשובה היא שכן נקבל תוצאות שונות אבל לא בערך המוחלט (לפחות בממוצע).

נעשה קצת סדר בדברים:

- הגודל $\tilde{S}_{xx}\left(\omega\right)$ הוא לא משתנה מקרי. זה בגלל שהפונקציה $R_x\left(\tau\right)$ היא פשוט פונקציה רגילה וידועה
- לאומת זאת הגודל $\tilde{X}\left(\omega\right)$ הוא כן משתנה מקרי ותלוי בריאליזציה של האות האקראי שלנו

זה אומר שמה שרשמנו נכון עבור אותות לא אקראיים. כדי לקשר בין השניים נצטרך לומר משהו על המתשנה האקראי $\tilde{X}\left(\omega\right)$.

כאן מגיע המשפט הכי חשוב בניתוח ספקטרי של אותות אקראיים:

משפט וינר חינצ'ין

נתון אות אקראי $x\left(t\right)$ סטציונרי במובן הרחב עם ממוצע $\mu_x=0$

נגדיר את הפונקציה הבאה:

$$x_T\left(t\right)=Rect\left(\frac{t}{T}\right)\cdot x\left(t\right)$$

כלומר הגבלה של האות האקראי שלנו לתחום $\left[-\frac{T}{2},\frac{T}{2}\right]$

אז:

$$\lim_{T\to\infty}\mathbb{E}\left[\left|\mathcal{F}\left[x_T\left(t\right)\right]\right|^2\right]=\tilde{S}_{xx}\left(\omega\right)$$

נפרק את המשפט לאט לאט. בצד ימים יש לנו את הפונקציה $\tilde{S}_{xx}\left(\omega\right)$ שאותה אנחנו מכירים והיא לא אות אקראי. בצד שמאל יש לנו את הגודל $\left|\mathcal{F}\left[x_T\left(t\right)\right]\right|^2$ שהוא כן משתנה מקרי. אנחנו ניקח את התוחלת שלו $\mathbb{E}\left[\left|\mathcal{F}\left[x_T\left(t\right)\right]\right|^2\right]$ זאת פונקציה של ω,T ואם ניקח את הגבול של $T\to\infty$ אז הצדדים שווים.

Warning

ממש חשוב לשים לב שהגבול הוא מחוץ לתוחלת ולא בתוך. כלומר לא לוקחים את התוחלת של הגבול אלא את הגבול של התוחלת

מסקנה חשובה שאנחנו רואים הוא שאנחנו לוקחים את הממוצע של הערך המוחלט בריבוע של הפורייה של הריאליזציה. האם יכול להיות שלשני אותות שונים יכול להיות אותו PSD אבל צורה שונה לחלוטין? התשובה היא כן. והסיבה היא שכל שני אותות שיש להם את אותה אוטוקורלציה יש להם את אותו PSD.

> לא ניתן לקבוע מה ההתפלגות של הרעש בזמן מסויים מתוך ה-PSD אלא רק את האוטוקורלציה

> מסקנה נוספת ונחמדה היא שה-**PSD הוא תמיד חיובי**

סינון רעש

מה קורה לאות אקראי אם אנחנו מעבירים אותו דרך מסנן? היינו רוצים לדעת איך זה משפיע על ה-PSD. האות המסונן יהיה $y(t) = \underbrace{x(t)}_{\text{אות—אקראי}} * \underbrace{h(t)}_{\text{מסנן}}$

אנחנו רוצעם לחשב את:

$$\mathcal{F}\left[\mathbb{E}\left[(x*h)(t),(x*h)(0)\right]\right] =?$$

אוקי זה מסובך. אבל כאן מגיע משפט וינר חינצ'ין לעזרתנו!

$$\tilde{S}_{yy}(\omega) = \lim_{T\to\infty}\mathbb{E}\left[\left|\mathcal{F}\left[x_T(t)*h(t)\right]\right|^2\right] = \lim_{T\to\infty}\mathbb{E}\left[\left|\left[\sqrt{2\pi}\tilde{X}_T(\omega)\cdot\tilde{H}(\omega)\right]\right|^2\right]$$

$$= 2\pi\lim_{T\to\infty}\mathbb{E}\left[\left|\left[\tilde{X}_T(\omega)\right]\right|^2\right]\cdot\left|\tilde{H}(\omega)\right|^2 = 2\pi\tilde{S}_{xx}(\omega)\cdot\left|\tilde{H}(\omega)\right|^2$$

קיבלנו תוצאה חשובה!

סינון רעש

אם יש לנו אות אקראי $x(t)$ ואנחנו מעבירים אותו במערכת לינארית (מסנן) $h(t)$

נקבל כי ה-PSD של האות המסוננת הוא פשוט המכפלה של ה-PSD של האות המקורית וערך המוחלט של התמסורת בריבוע

$$\tilde{S}_{yy}(\omega) = 2\pi\tilde{S}_{xx}(\omega)\cdot\left|\tilde{H}(\omega)\right|^2$$

Warning

אנחנו יודעים איך סינון רעש משפיע על ה-PSD אבל זה מאוד לא ברור מה הוא עושה ל-PDF של הרעש בכל זמן. ראינו שיש הרבה רעשים שונים עם אותו PSD ובפרט סינון של רעש יכול לשנות דרסטית את ה-PDF שלו.

לדוגמה אם ניקח רעש לבן (זמן לא רציף אלא דגום) עם התפלגות אחידה על הקטע $[-1,1]$ אז סינון לינארי הוא פעולת קונבולוציה כלומר חיבור של הרבה משתנים שמתפלגים אחיד כל אחד כפול מספר אחר. אם ניקח קונבולוציה עם חלון (מיצוע לאורך זמן) אפילו נקבל ממש ממוצע.

מה קורה כשממצאים הרבה משתנים שמתפלגים אחיד? התוצאה שואפת להתפלגות גאוסיינית!

> מקרה חריג הוא המקרה בו ההתפלגות היא גאוסיין. במקרה כזה כל סינון לינארי משאיר את ההתפלגות גאוסיינית

חיבור רעשים

אם יש לנו שני רעשים אקראיים $x_1(t), x_2(t)$ ואנחנו מחברים אותם. איך נראת האוטוקורלציה של החיבור?

$$R_{x+y}(\tau) = \mathbb{E}\left[(x(\tau)+y(\tau))\cdot(x(0)+y(0))\right] = \mathbb{E}\left[x(\tau)\cdot x(0)\right] + \mathbb{E}\left[y(\tau)\cdot y(0)\right] + \mathbb{E}\left[y(\tau)\cdot x(0)\right.$$

$$= R_x(\tau) + R_y(\tau) + \underbrace{\mathbb{E}\left[y(\tau)\cdot x(0) + x(\tau)\cdot y(0)\right]}_{0?}$$

האיבר האחרון נקרא הקרוסקורלציה. אם הרעשים הם לא תלויים אז הקרוסקורלציה שווה 0 ואז:

$$R_{x+y}(\tau) = R_x(\tau) + R_y(\tau)$$

> עבור אותות לא תלויים (0 קרוסקורלציה) $R_{x+y}(\tau) = R_x(\tau) + R_y(\tau)$
>
> נשים לב שזה גם אומר שה-PSD מתחברים $\tilde{S}_{x+y,x+y}(\omega) = \tilde{S}_{xx}(\omega) + \tilde{S}_{yy}(\omega)$

הספק תדרי

כבר ראינו שאנחנו מודדים את ההספק של הרעש לפי $R_x\left(0\right)$. עבור רעש עם ממוצע $\mu_x = 0$. ראינו לפני רגע שאם האותות לא תלויים אז האוטוקורלציות מתחברות. וזה אומר שההספק מתחבר.

אם ההספק מתחבר מה קורה לאמפליטודות? אנחנו מודדים את האמפליטודות בעזרת $\sigma_x = \sqrt{R_x\left(0\right)}, \sigma_y = \sqrt{R_y\left(0\right)}$ זה אומר ש:

$$\sigma_{x+y} = \sqrt{\sigma_x^2 + \sigma_y^2}$$

או באופן כללי אם מחברים N רעשים שונים:

$$\sigma_s = \sqrt{\sum_{i=1}^{N} \sigma_i^2}$$

מה יקרה אם נשעה N מדידות שונות לאותו האות ונמצע אותן? האמפליטודה של חיבור הרעשים תהיה רק $\sqrt{N}$ חזקה יותר לאומת האמפליטודה של האות שתגדל ב-N. ולכן בממוצע האות ישאר כמו שהוא אבל הרעש יחלש (באמפליטודה) ב$\frac{1}{\sqrt{N}}$

רעשים פיזיקלים

Contents

- shot noise
- רעש תרמי

הרבה מערכות פיזיקליות (חשמליות) דומות במקורות הרעש שלהן. ובפרט יהיו כמעט תמיד שני מקורות רעש שנמצאים שם:

- רעש תרמי - רעש הנובע מתנועה אקראית של האלקטרונים
- רעש שוט - רעש הנוסע מזה שנושאי המטען הם חלקיקים ולא זרם רציף

shot noise

הזרם שאנחנו מודדים תמיד מורכב מנושאי מטען בודדים (לרוב אלקטרונים אבל יכול להיות גם יונים אחרים). ולכן אם אנחנו מודדים "זרם" קבוע בפועל הוא לא קבוע. הזרם הוא רק הממוצע זה אומר שאם נמדוד בזמנים מספיק קטנים נוכל למדוד את המטענים הבודדים.

נניח הנחה שהיא רק קירוב של המציאות: **בכל רגע יש הסתברות קבועה למדידה של נושא מטען**

ההנחה הזו אומרת לנו שכמות נושאי המטען שנמדוד בזמן סופי כלשהו היא פואסונית ואנחנו מניחים שההגעה של אלקטרונים היא בלתי תלויה. כלומר הרעש לבן.

איך נראה הזרם באמת? כל פעם שמגיע מטען הזרם הוא δ ובין לבין הוא פשוט 0. זה אומר שהצורה האמיתית של הזרם היא:

$$I\left(t\right)=q\sum_{n}\delta\left(t-t_{n}\right)$$

כאשר הזמנים t_n עצמם הם רנדומאלים ודואגים שההתפלגות תהיה פואסונית

למה הכוונה התפלגות פואסונית? הכוונה היא שמספר המטענים שעברו במוליך (במקום שאנחנו מודדים את הזרם) בחלון זמן T מתפלג פואסונית. כמה מטענים עברו במוליך? בזמן T? אם נחשב את האינטגרל על הזרם ונחלק במטען נקבל את התשובה. כלומר:

$$\underbrace{N\left(T\right)}_{\text{מסמטענים}}=\frac{1}{q}\int\limits_{-\frac{T}{2}}^{\frac{T}{2}}I\left(t\right)dt$$

המספר הזה מתפלג פואסונית ולכן אם נגדיר את $\left\langle I\right\rangle_{T}\left(t\right)=q\cdot N\left(t\right)$ נקבל את הזרם הממוצע בזמן T ואת ההפתלגות שלו:

$$N\left(T\right)\sim Pois\left(\lambda\cdot T\right)\Rightarrow\left\langle I\right\rangle_{T}=\int\limits_{-\frac{T}{2}}^{\frac{T}{2}}I\left(t\right)dt\sim q\cdot Pois\left(\lambda\cdot T\right)$$

עכשיו ניתן לשאול מה הוא $\boldsymbol{\lambda}$ נרצה כי הזרם הממוצע יהיה $\left\langle I\right\rangle$ שהוא הזרם שאנחנו מודדים

זה אומר כי:

$$q\lambda T\underbrace{=}_{\mathbb{E}[Pois(\alpha)]=\alpha}\mathbb{E}\left[\left\langle I\right\rangle_{T}\right]=\mathbb{E}\left[\int\limits_{-\frac{T}{2}}^{\frac{T}{2}}I\left(t\right)dt\right]=T\cdot\left\langle I\right\rangle$$

כלומר:

$$\lambda=\frac{\left\langle I\right\rangle}{q}$$

אנחנו יודעים שהרעש הוא לבן ושעבור רעש לבן ה-PSD הוא קבוע (אם הממוצע הוא 0) נוכל להסתכל על התהליך המקרי $x\left(t\right)=I\left(t\right)-\left\langle I\right\rangle$ שיש לו ממוצע 0 והוא גם לבן. נשתמש במשפט וינר חינצ'ין על מנת לחשב את הערך של PSD עבור ערך ספציפי (זה כמובן לא משנה כי ה-PSD קבוע)

צריך קודם כל להגדיר אות:

$$x_{T}\left(t\right)=Rect\cdot\left(\frac{t}{T}\right)x\left(t\right)$$

ואז נוכל לרשום כי:

$$S_{xx}\left(\omega\right)=S_{xx}\left(0\right)=\lim_{T\to\infty}\frac{1}{T}\mathbb{E}\left[\left|\mathcal{F}\left[x_{T}\left(t\right)\right]\left(\omega=0\right)\right|^{2}\right]$$

נשים לב שלעשות פורייה ולקחת את המקום ה-0 זה כמו למצע בזמן

$\mathcal{F}\left[x_{T}\left(t\right)\right]\left(\omega=0\right)=\int_{-\infty}^{\infty}Rect\cdot\left(\frac{t}{T}\right)x\left(t\right)dt=\int_{-\frac{T}{2}}^{\frac{T}{2}}x\left(t\right)dt=\left(\left\langle I\right\rangle_{T}\left(t\right)-T\left\langle I\right\rangle\right)$

זה אומר כי:

$$S_{xx}(0)=\lim_{T\to\infty}\frac{1}{T}\mathbb{E}\left[\left(\langle I\rangle_T(t)-T\langle I\rangle\right)^2\right]=\lim_{T\to\infty}\frac{1}{T}\left(\mathbb{V}\left[\langle I\rangle_T(t)\right]\right)=\lim_{T\to\infty}\frac{1}{T}\left(q^2\lambda T\right)=q\langle I\rangle$$

מה קרה כאן? השתמשנו בכך שהתוחלת על משתנה מקרי $\langle I\rangle_T(t)$ פחות התוחלת שלו $T\langle I\rangle$ בריבוע זה פשוט ה-VAR שלו. בגלל שה-PSD קבוע היה מספיק לנו לחשב נקודה אחת.

קיבלנו כי:

$$\boxed{S_{xx}(f)=q\langle I\rangle}$$

מסקנות:

- הרעש יותר גדול ככל שהזרם יותר גדול
- אם יש לנו פילטר לתחום תדרים $\Delta f=f_2-f_1$ נקבל כי גודל הרעש על נגד בגודל R הוא $\langle P\rangle=2qR\langle I\rangle\Delta f$

מה הוא ה-SNR של רעש שוט כאשר מודדים על נגד בגודל R?

$$SNR=\frac{\langle P_{sig}\rangle}{\langle P_{noise}\rangle}=\frac{R\langle I\rangle^2}{2eR\langle I\rangle\Delta f}=\frac{\langle I\rangle}{2e\Delta f}$$

למה פקטור 2?

למה כאשר שמנו פילטר בעל רוחב $\Delta f=f_2-f_1$ קיבלנו שההספק הוא $\langle P\rangle=2qR\langle I\rangle\Delta f$ ולא $\langle P\rangle=qR\langle I\rangle\Delta f$

הסיבה היא שה-PSD סימטרי וכך גם הפילטר. כלומר פילטר שמשאיר רק את התדרים בתחום $[f_1,f_2]$ משאיר גם את התדרים בתחום $[-f_2,-f_1]$ ולכן כשמחשבים את האינטגרל מקבלים פקטור 2.

איך נגדיל את יחס האות לרעש?

- נבחר $\Delta\omega$ כמה שיותר קטן כך שהוא לא מסנן לנו את האות
- נגדיל את הזרם הממוצע שלנו
- נקטין את מטען האלקטרון :)

רעש תרמי

יש לנו מוליך שמלא באלקטרונים. אבל בגלל שיש תמית טמפרטורה כלשהי האלקטרונים לא עומדים במקום אלא זורמים לכלל הכיוונים. נגיד שכיוון הזרימה במוליך שלנו הוא x. אנחנו מעוניינים לדעת מה המהירות הממוצעת או יותר נכון מה הספק הרעש.

לא נעשה כאן ניתוח שלם אבל רק נבין איך הגדלים נכנסים לבעייה.

הקשר בין טמפרטורה למהירות הוא חוק ידוע בתרמודינמיקה: וביקירוב ניתן לומר כי:

$$\frac{1}{2}mu_x^2 = \frac{1}{2}k_BT$$

אנחנו יודעים שהספק האות מתכונתי לזרם בריבוע שמתכונתי למהירות בריבוע:

$$\langle P \rangle \propto \langle I \rangle^2 \propto \langle u_x^2 \rangle \propto k_BT$$

ניתוח מעמיק יותר של המערכת יתן בדיוק את הקבועים. וכמו קודם נניח שאנחנו מודדים את הרעש במערכת שמסננת את כלל התדרים חוץ מרצועה בגודל Δf. נקבל כי:

$$\langle P \rangle = RS_{II}\left(f\right) = 4k_BT\Delta f$$

כלומר הספק הרעש לינארי בטמפרטורה.

סינון רעש

Print to PDF

Contents

- רעש ואות לא חופפים
- רעש לבן
- שחזור אופטימלי - wiener filter

איך אנחנו מסננים רעש על מנת להשיג את ה-SNR הכי טוב שאנחנו יכולים? נניח שאנחנו משתמשים רק בפילטרים לינארים. כלומר מסננים את הרעש (ואת האות) בתדר.

מה הסינון האופטימלי? ובאיזה מובן הוא אופטימלי?

נתחיל מכמה מקרים פשוטים:

רעש ואות לא חופפים

במקרה הזה ברור שמה שצריך לעשות הוא BPF מסביב לאות ולסנן את כל הרעש.

אין הרבה מה לעשות מעבר ורק צריך לומר שהסיטואציה הזו היא לא באמת פיזיקאלית אבל היא יכולה להיות התמונה בקירוב

רעש לבן

כאן זה גם קצת יותר טריקי אבל גם כאן יחסית ברור שמה שצריך לעשות הוא BPF מסביב לאות. אבל לא ברור האם צריך להשתמש בפילטר מלבני או לא. מה אם יש תדרים בהם האות הוא מאוד נמוך?

שחזור אופטימלי - wiener filter

אם אנחנו רוצים לשחזר את האות ולא רק להבין אם הוא שם נרצה פילטר שמסנן לנו תדרים בהם ה-SNR הוא נמוך ומעביר תדרים בהם ה-SNR הוא גבוה.

יש כל מיני שיטות לעשות את זה אבל אחת מהן היא לומר שאנחנו רוצים למנם את האנרגיה של השגיאה בין האות המקורי ובין האות המסונן. כלומר:

$$\min_{\tilde{H}(\omega)} \int_{-\infty}^{\infty} \left(y\left(t\right)-s\left(t\right)\right)^2 dt = \min_{\tilde{H}(\omega)} \int_{-\infty}^{\infty} \left|\tilde{Y}\left(\omega\right)-\tilde{S}\left(\omega\right)\right|^2 d\omega = \min_{\tilde{H}(\omega)} \int_{-\infty}^{\infty} \left|\tilde{H}\left(\omega\right)\left(\tilde{S}\left(\omega\right)+\tilde{N}\left(\omega\right)\right)-\tilde{S}\left(\omega\right)\right|^2 d\omega$$

מכאן די ברור שהנוסחא שלנו צריכה להיות:

$$\tilde{H}\left(\omega\right) = \frac{\tilde{S}\left(\omega\right)}{\tilde{S}\left(\omega\right)+\tilde{N}\left(\omega\right)} = \frac{1}{1+\frac{\tilde{N}(\omega)}{\tilde{S}(\omega)}} = \frac{1}{1+\frac{1}{SNR(\omega)}}$$

- עבור $SNR\left(\omega\right) \gg 1$ נקבל $\tilde{H}\left(\omega\right) = 1$
- עבור $SNR\left(\omega\right) \ll 1$ נקבל $\tilde{H}\left(\omega\right) = 0$

נשים לב שממש איפטמנו על להיות כמה שיותר קרובים לסיגנל המקורי כך שבתקווה נקבל באמת אות דומה ככל האפשר.

תורת הגילוי

Contents

- (על קצה המזלג)
- ROC Curve
- גילוי אופטימלי - match filter
- דוגמא - גילוי של מכ"ם

(על קצה המזלג)

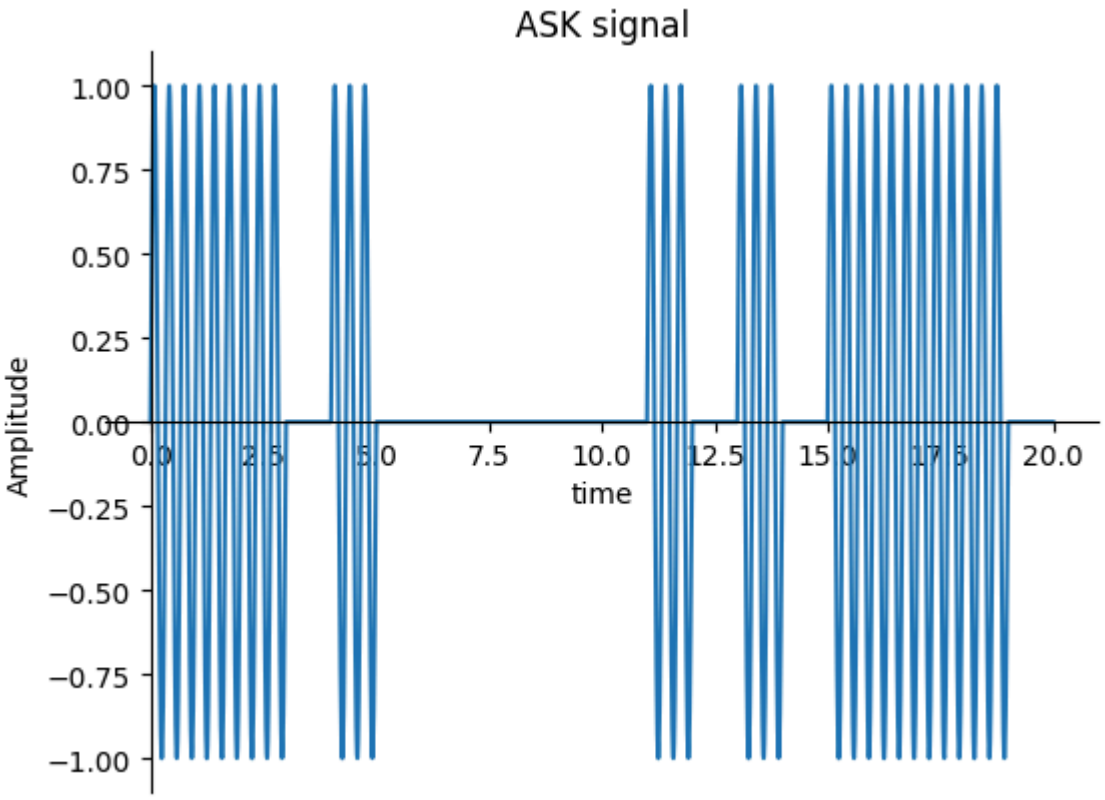
בהרבה מערכות המטרה היא לקבל החלטה מתוך מדידות. "כן" או "לא".

דוגמאות:

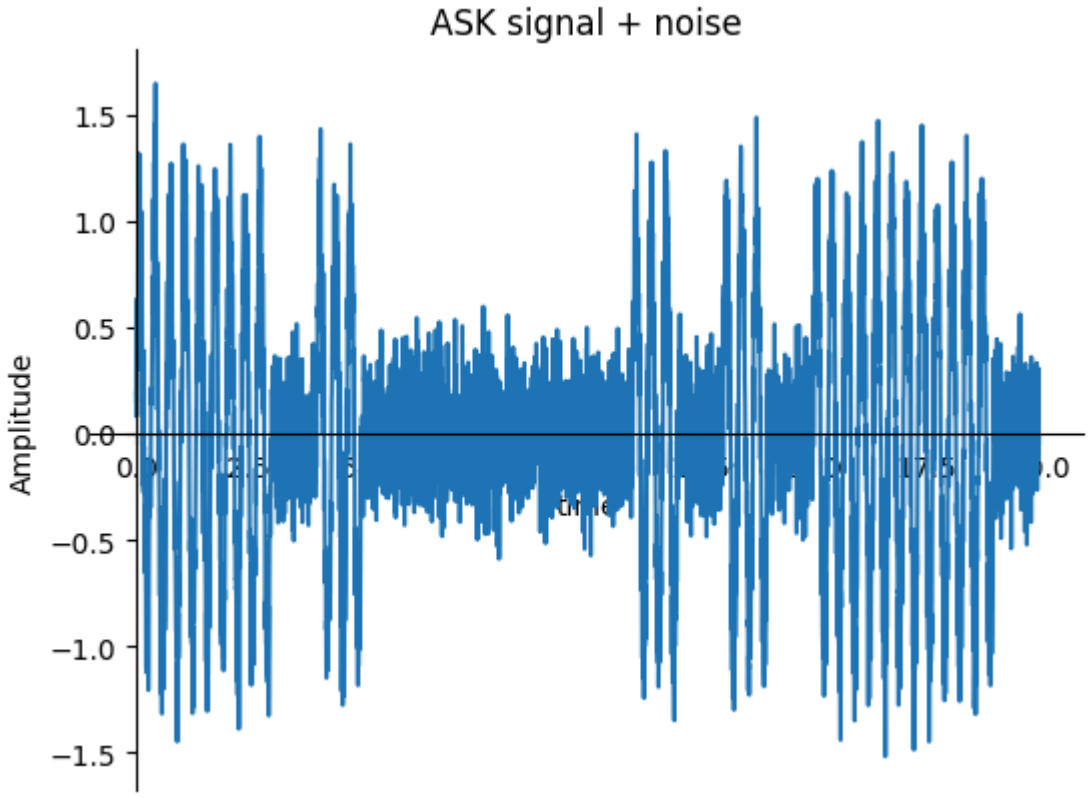
- מכ"ם - האם יש מטרה או לא
- סונאר - אותו הדבר אבל עם אות אקוסטי
- מערכת גילוי אש
- מערכת אבטחה - נגיעה בגדר לדוגמא
- תקשורת דיגיטלית - להחליט איזה סימבול נשלח
- התרעה מפני רעידות אדמה

ניקח לדוגמא מערכת של תקשורת דיגיטלית שמשדרת באפנון BASK. המטרה היא להחליט עבור כל זמן סמל האם הוא "0" או "1". כמובן שאם יש רק אות נקי אין שום בעיה ליצור אלגוריתם שמפריד בין שני הסימבולים האפשריים אבל מה קורה כשיש רעש?

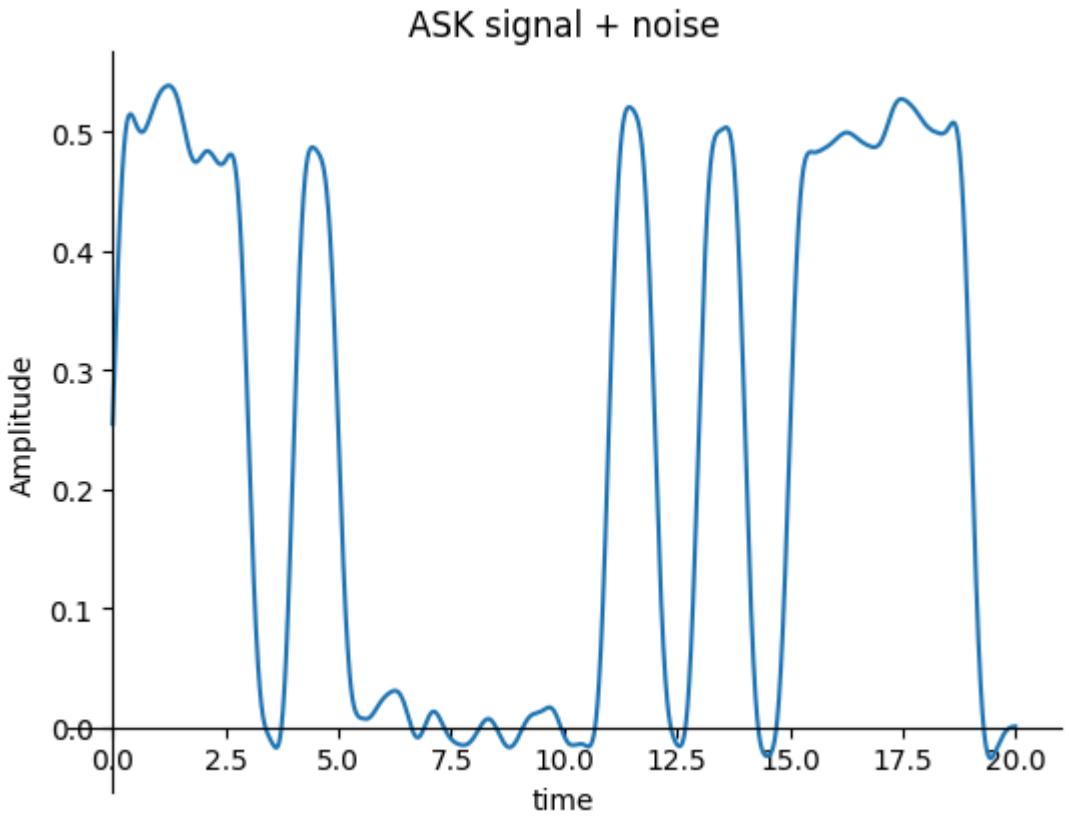
כשאין רעש הסיגנל המתקבל נראה ככה:



אבל עם רעש הסיגנל נראה יותר ככה:

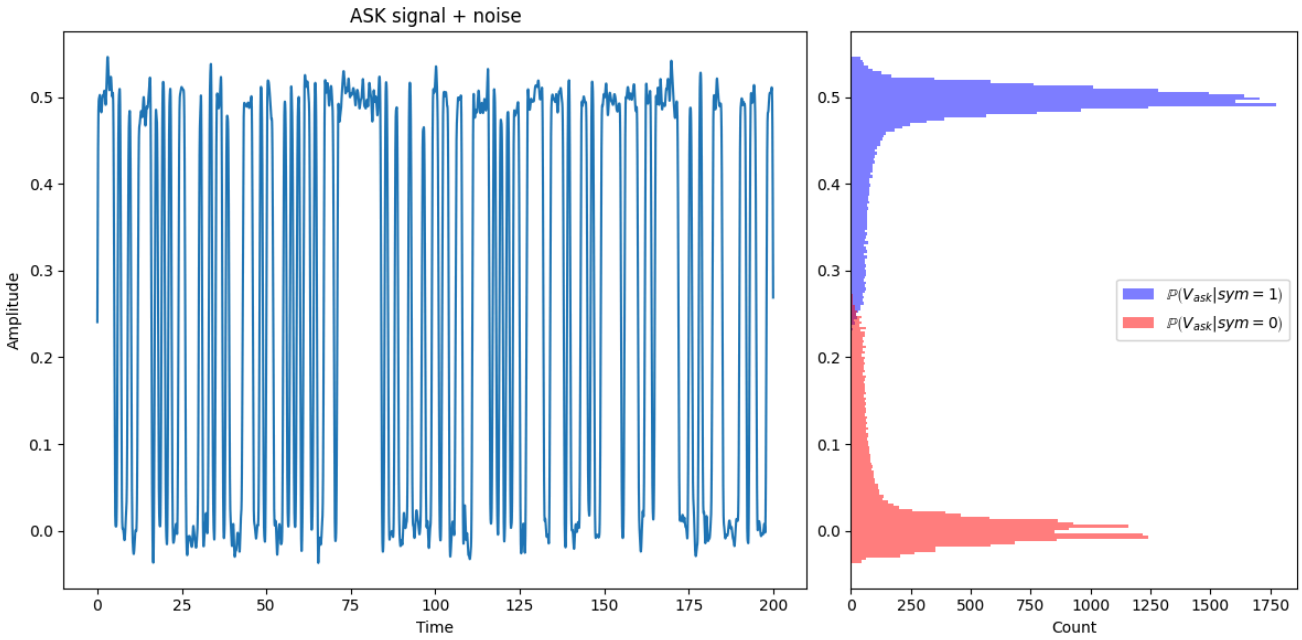


אחרי מעבר במקלט קוהרנטי (מסונכרן פאזה) נקבל סיגנל שנראה פחות אות יותר ככה:



ועכשיו מגיע החלק המעניין. אנחנו צריכים להחליט האם קיבלנו 0 או 1 בכל זמן סימבול. תמיד נעשה את זה על ידי החלטה על סף כלשהו

צורה יותר נוחה להסתכל על הבעיה הזו היא לשאול מה הוא הערך של הגרף בהינתן שאנחנו יודעים מה הסימבול. בגלל הרעש אין תשובה אחת אלא התפלגות. לדוגמא במקרה שלנו

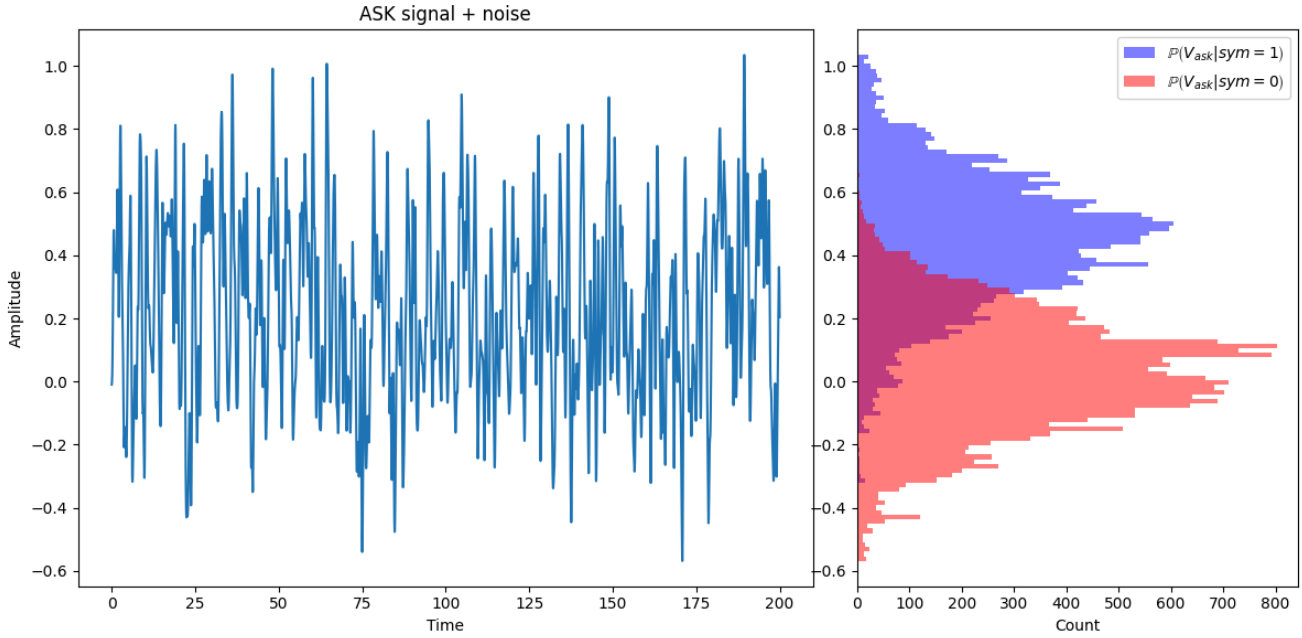


כאשר באדום אתם רואים את התפלגות הערכים של הסיגנל כאשר הסימבול הוא 1 ובכחול כאשר הסימבול הוא 0. האם אנחנו רוצים להעביר את הסף ב-0.5? זה תלוי מה אנחנו רוצים לעשות.

אבל באופן כללי כאן פעם ראשונה אנחנו נתקלים בפורמליזם שלנו בו יש התפלגות שונה לסיגנל בהינתן מה שאנחנו רוצים לגלות. נסמן את שתי ההתפלגויות:

- ההתפלגות בהינתן "1" (יש סיגנל) - $\mathbb{P}\left(V_{ask}|''1''\right)$
- ההתפלגות בהינתן "0" (אין סיגנל) - $\mathbb{P}\left(V_{ask}|''0''\right)$

במקרה שלנו נראה שאפשר להפריד ממש בקלות. מה קורה אם הרעש ממש גדל?



עכשיו הרבה יותר קשה להחליט האם הסימבול הוא "0" או "1".

נוכל עכשיו להגדיר שני מדדים מאוד חשובים נחשוב על הזמנים בהם משודר "1" בתור הזמנים בהם יש אירוע מסויים שאנחנו רוצים לגלות. לדוגמא שריפה או נגיעה בגדר וכו.

- ההסתברות לגילוי - $P_d = \int_{V_{th}}^{\infty} \mathbb{P}\left(V|''1''\right)dV$
- ההסתברות להתרעות שוא - $P_{FA} = \int_{V_{th}}^{\infty} \mathbb{P}\left(V|''0''\right)dV$

נשים לב שאם הסף שלנו V_{th} יהיה ∞ נקבל 0 FA אבל גם בלי גילויים בכלל בעוד שאם הסף יהיה $-\infty$ נקבל בדיוק הפוך. תמיד נגלה אבל גם תמיד יהיו התרעות שוא.

> אנחנו רוצים לשאוף למצב בו $P_d = 1$ וגם $P_{FA} = 0$ אבל נשים לב שאם יש חפיפה בין פונקציות צפיפות ההסתברות לא נוכל לעשות את זה לא משנה מה הוא הסף V_{th} שנבחר

ROC Curve

בגלל שאנחנו רוצים לבחון את הביצועים של מערכת הגילוי שלנו אנחנו רוצים למדוד אותה לא כתלות בסף אותו בחרנו. מה שלרוב עושים הוא בודקים את ביצועי המערכת בכל הספים האפשריים.

עבור כל סף נקבל שני מספרים P_d ו-P_{FA}. הגרף אשר מציג את כל הנקודות האלו נקרא גרף ROC והוא נראה ככה:

בבירור הגרף צריך להיות מעל הישר בו $P_d = P_{FA}$ משום שאחרת אפשר להחליף את הזמנים שבהם מתריעים עם הזמנים שלא מתריעים ולשפר את הביצועים.

אם יש שתי מערכות התרעה (כמו בתמונה) בהן אחת תמיד נמצאת מעל השנייה נוכל לומר שאחת טובה יותר תמיד מהשנייה. אבל זה לא תמיד המצב ולכן נחפש מדד של מספר שאומר לנו כמה מערכת גילוי היא "טוב". מדד מקובל נקרא AUC (Area Under Curve)

וכשמו כן הוא:

> AUC הוא השטח מתחת לגרף ה-ROC

דוגמה לחישוב FAR

הרבה פעמים במערכות מספר חשוב הוא כמות התרעות השוא. המספר שאנחנו נתנו P_{FA} הוא רק הסיכוי במדידה כלשהי לקבל FA. כדי לקבל את ה-FAR (False Alarm Rate) צריך להכפיל בקצב המדידות שלנו. ובאופן כללי אם אנחנו מודדים בקצב f:

$$FAR = P_{FA} \cdot f$$

לרוב יהיה מספר איתו המערכת יודעת להתמודד. נגיד התרעת שוא אחת ביום, הוא אחת בחודש או אחת בשנה וכו. תלוי המקרה.

מהחסם הזה ניתן לחסום את P_{FA} וככה גם לבחור V_{th} מתאים.

גילוי אופטימלי - match filter

אחת הבעיות הנפוצות בעיבוד אותות הוא זיהוי של אות ידוע מראש אך בזמן לא ידוע. ננסה לפתור את הבעיה **עבור רעש לבן** (אני אומר כאן בסוגריים שהרבה פעמים עושים תהליך שנקרא הלבנה של הרעש. כלומר מעבירים בפילטר שגורם ל-PSD להיות קבוע ורק אז משתמשים ב-match filter)

נתחיל עם הנחה מקלה שאנחנו רוצים להבחין בין שני מצבים.

1. קלטנו רק רעש - $\mathcal{H}_0 : r(t) = \xi(t)$
2. קלטנו אות ורעש - $\mathcal{H}_1 : r(t) = s(t) + \xi(t)$

מה נעשה כדי להבדיל בין השניים?

מה יקרה אם נסתכל על הפעולה:

$$r_{match} = \int_{-\infty}^{\infty} r\left(t\right) \cdot s^{*}\left(t\right) dt$$

נשים לב כי:

$$r_{match} = \int_{-\infty}^{\infty} r\left(t\right) \cdot s^{*}\left(t\right) dt = \mathbb{E}\left[r\left(t\right) \cdot s^{*}\left(t\right)\right] = \begin{cases} E_s + \mathbb{E}\left[r\left(t\right) \cdot \xi^{*}\left(t\right)\right] & \mathcal{H}_1 \\ \mathbb{E}\left[r\left(t\right) \cdot \xi^{*}\left(t\right)\right] & \mathcal{H}_0 \end{cases}$$

כמובן שאין לנו אף פעם אות אינסופי אבל בעיקרון $\mathbb{E}\left[r\left(t\right) \cdot n^{*}\left(t\right)\right]$ הוא 0 אם זמן האינטגרציה הוא אינסופי.

נשים לב שמה שכתבנו היא פשוט מכפלה פנימית בין האות שלנו ובין האות $s^{*}\left(t\right)$.

ננתח איך זה נראה בדגימה אמיתית. נניח שיש לנו סיגנל $s\left[n\right]$ באורך N ורעש לבן גאוסייני $\xi\left[n\right] \sim \mathcal{N}\left(0, \sigma^2\right)$ כאשר הפעולה שאנחנו מחשבים היא:

$$r_{match} = \sum_{n=0}^{N-1} r\left[n\right] \cdot s^{*}\left[n\right] = \begin{cases} \sum_{n=0}^{N-1} \left|s\left[n\right]\right|^2 + \sum_{n=0}^{N-1} \xi\left[n\right] \cdot s^{*}\left[n\right] & \mathcal{H}_1 \\ \sum_{n=0}^{N-1} \xi\left[n\right] \cdot s^{*}\left[n\right] & \mathcal{H}_0 \end{cases}$$

נסתכל על הביטוי $\sum_{n=0}^{N-1} \xi\left[n\right] \cdot s^{*}\left[n\right]$ אפשר לחשוב עליו בתור ממוצע משוקלל של משתנים גאוסיינים בלתי תלויים.

הממוצע כמובן נשאר 0 משום ש:

$$\mathbb{E}\left[\sum_{n=0}^{N-1} \xi\left[n\right] \cdot s^{*}\left[n\right]\right] = \sum_{n=0}^{N-1} \underbrace{\mathbb{E}\left[\xi\left[n\right]\right]}_{0} \cdot \mathbb{E}\left[s^{*}\left[n\right]\right] = 0$$

ומה עם ה-Var?

$$\mathbb{V}\left[\sum_{n=0}^{N-1} \xi\left[n\right] \cdot s^{*}\left[n\right]\right] = \sum_{n=0}^{N-1} \mathbb{V}\left[\xi\left[n\right] \cdot s^{*}\left[n\right]\right] = \sum_{n=0}^{N-1} \left(s^{*}\left[n\right]\right)^2 \underbrace{\mathbb{V}\left[\xi\left[n\right]\right]}_{\sigma^2} \underbrace{=}_{s^{*}[n] \in \mathbb{R}} \sigma^2 \sum_{n=0}^{N-1} \left(s\left[n\right]\right)^2$$

כלומר ה-Var מוכפל ב-$\sum_{n=0}^{N-1} \left(s\left[n\right]\right)^2$ נשים לב שזו הייתה בדיוק ההגדרה שלנו לאנרגיה של האות

$$E_s \equiv \sum_{n=0}^{N-1} \left(s\left[n\right]\right)^2$$

קיבלנו לבסוף כי:

$$r_{match} = \begin{cases} E_s + \xi_N & \mathcal{H}_1 \\ \xi_N & \mathcal{H}_0 \end{cases}$$

כאשר $\xi_N \sim \mathcal{N}\left(0, \sigma^2 \cdot E_s\right)$

או אם ננרמל את התוצאה באנרגיה של האות:

$$\frac{r_{match}}{E_s} = \begin{cases} 1 + \zeta & \mathcal{H}_1 \\ \zeta & \mathcal{H}_0 \end{cases}$$

$$\zeta \sim \mathcal{N}\left(0, \frac{\sigma^2}{E_s}\right)$$

ככל שהאות שלנו יותר חזק נקבל שהרעש קטן. בפרט סטיית התקן קטנה ב-$\sqrt{E_s}$

שימו לב שמכאן ממש נוח לחשב את P_d, P_{FA} כתלות ב-SNR. עבור V_{th} שונים.

כאן אפשר להסביר מה זה אומר ש-match filter הוא אופטימלי. זה אומר שעבור **כל** P_{FA} כלשהו ב-SNR מסויים האלגוריתמיקה של match-filter נותן את ה-P_d הכי גבוה בין כל הדטקטורים האפשריים!

לקריאה נוספת אתם מוזמנים להתחיל מדף הויקיפדיה הזה

תנו לזה רגע לחלחל. **כל דטקטור** אחר יתן P_d נמוך יותר עבור אותו P_{FA} אי אפשר להיות טובים יותר!

אם רוצים לשפר את הביצועים יש לנו אפשרות אחת

- **לשפר את ה-SNR**

מה אם לא יודעים את זמן הגעת האות? כלומר מה אם האות שמתקבל הוא:

$$\mathcal{H}_1 : r\left(t\right) = s\left(t - t_0\right) + n\left(t\right)$$

אנחנו יכולים פשוט להריץ חיפוש. כלומר לנסות את כל הערכים האפשריים. איך עושים את זה?

$$r_{match}\left(t\right) = \int_{-\infty}^{\infty} r\left(\tau\right) \cdot s^*\left(\tau - t\right) d\tau = r\left(t\right) * s\left(-t\right)$$

כלומר פשוט מעבירים את הסיגנל דרך פילטר של $h\left(t\right) = s\left(-t\right)$ ואז מחפשים את המקסימום באות.

מה האות שמתקבל? אז האמת שאנחנו כבר יודעים את התשובה. ניתן לחזור על אות החישובים אבל הפעם עם אינטגרלים וסינון רעשים במקום חישובים של תוחלת ושונות.

$$\frac{r_{match}\left(t\right)}{E_s}=\begin{cases}\frac{s(t-t_0)*s(-t)}{E_s}+\frac{\xi(t)*s(-t)}{E_s} & \mathcal{H}_1\\ \frac{\xi(t)*s(-t)}{E_s} & \mathcal{H}_0\end{cases}$$

את הפעולה $s\left(t-t_0\right)*s\left(-t\right)$ אנחנו כבר מכירים. זאת האוטוקורלציה של האות אבל מוזזת סביב t_0.
והמקסימום שלה הוא האנרגיה של האות.

ומה עם $\xi\left(t\right)*s\left(-t\right)$ זה רעש שעבר פילטר. נוכל לשאול איך השתנה ה-PSD שלו. נגדיר $\zeta\left(t\right)=\frac{\xi(t)*s(-t)}{E_s}$ ונקבל:

$$\tilde{S}_{\zeta\zeta}\left(\omega\right)=\tilde{S}_{\xi\xi}\left(\omega\right)\left|\frac{S^*\left(\omega\right)}{E_s}\right|^2=\frac{1}{E_s^2}\tilde{S}_{\xi\xi}\left(\omega\right)\left|S\left(\omega\right)\right|^2$$

ואם אנחנו שואלים את עצמנו מה ההספק הממוצע שיש ברעש כדי לחשב SNR:

$$\left\langle P_\zeta\right\rangle=R_\zeta\left(0\right)=\int_{-\infty}^{\infty}\tilde{S}_{\zeta\zeta}\left(\omega\right)d\omega=\int_{-\infty}^{\infty}\frac{1}{E_s^2}\sigma^2\left|S\left(\omega\right)\right|^2d\omega=\frac{1}{E_s^2}\sigma^2\underbrace{\int_{-\infty}^{\infty}\left|S\left(\omega\right)\right|^2d\omega}_{E_s}=\frac{\sigma^2}{E_s}$$

זה אומר שההספק הממוצע קטן ב-E_s כמו במקרה הבדיד.

נסכם:

> אם יש לנו אות $r\left(t\right)=s\left(t-t_0\right)+n\left(t\right)$ ואנחנו מעבירים אותו ב-match filter כלומר בפילטר $h\left(t\right)=s\left(-t\right)$ נקבל אות:
>
> $$r_{match}\left(t\right)=E_s\left(\frac{R\left(t-t_0\right)}{E_s}+\zeta\left(t\right)\right)$$
>
> כאשר ההספק הממוצע של הרעש הוא
>
> $$\left\langle P_\zeta\right\rangle=\frac{\sigma^2}{E_s}$$
>
> והמקסימום של הסיגנרל שהוא לא הרעש הוא פשוט:
>
> $$\max_t\frac{R\left(t-t_0\right)}{E_s}=\frac{R\left(0\right)}{E_s}=1$$
>
> זה אומר שאחרי match filter ה-SNR שלנו תלוי לינארית ב-E_s שזה נהדר! כי זה לא תלוי באמפליטודה שלנו אלא באמפליטודה בריבוע.

דוגמא - גילוי של מכ״ם

נניח שאתם מכם שמשדר אות פולסי $s\left(t\right)$ ומחכה לתשובה. המכ״ם מעביר את האות הנקלט ב-match filter ובודק אם המקסימום עובר סף V_{th} כלשהו.

נרצה לענות על כמה שאלות:

1. מה הם ה-P_d, FAR של המערכת
2. אם אנחנו רוצים לחסום את ה-FAR איזה SNR אנחנו יכולים להרשות לעצמנו

נתחיל בלחשב את P_d, P_{FA}

אם נסתכל על האות אחרי דגימה נקבל (בהנחה מקלה שזמן ההגעה של ההחזר הוא אחד מזמני הדגימה):

$$r\left[n\right]=\begin{cases}A\cdot s\left[n-n_0\right]+\xi\left[n\right] & \mathcal{H}_1\\ \xi\left[n\right] & \mathcal{H}_0\end{cases}$$

נניח לרגע שאיך שהמכ״ם עובד זה השהוא שולח פולס ואז מקשיב (ודוגם) במשך N דגימות. אחרי זה הוא שולח עוד פולס כדי לחפש את המטרה הבאה. בכל מקטע כזה באורך N אנחנו רוצים להחליט אם מצאנו מטרה או לא.

על כל מקטע כזה נריץ match-filter ואז ניקח מקסימום. כלומר:

$$r_{match}=\max_{0\leq n\leq N-1}r\left[n\right]*s\left[-n\right]$$

כדי לחפש את P_d, P_{FA} נצטרך לענות על השאלה איך מתפלג המספר r_{match} בכל אחד מהמקרים:

$$P_d=\int\limits_{r_{th}}^{\infty}\mathbb{P}\left(r_{match}|\mathcal{H}_1\right)dr_{match}$$

$$P_{FA}=\int\limits_{r_{th}}^{\infty}\mathbb{P}\left(r_{match}|\mathcal{H}_0\right)dr_{match}$$

לא הכי פשוט לענות על השאלה מי הן ההתפלגויות משום שהרעש לא לבן אחרי הפילטר. אם לא היינו לוקחים max אלא מסתכלים על דגימה מסויימת היינו מקבלים ששתי ההתפלגויות הן גאוסייניות והחישובים היו קלים. די בקלות אפשר לעשות סימולציה למקרה הזה. מזמין אתכם לנסות וליצור עקומת ROC.

אנחנו רוצים ליצור את הפילטר האידאלי כלומר וקטור שאם אני אעשה איתו קונבולוציה אני אכפיל במלבן מושלם בתדר. המטרה שלכם היא ליצור אות סופי בגודל 100 אשר הפורייה שלו כמה שיותר קרוב למלבן בתדר. שימו לב שכאשר אתם עושים FFT לסיגנל שלכם אתם דוגמים רק 100 תדרים. אני ממליץ לרפד באפסים וככה לדגום יותר תדרים ולראות כמה הפילטר שלכם טוב. פונקציית המטרה היא למנם את המרחק מהחלון האידאלי בנורמת L1.

מומנים לבדוק בעזרת פונקציית הניקוד הבאה (אני לא מתחייב על איזה pad_length אני אשתמש אבל הוא יהיה גבוה)

מבוא ל-DFT

Contents

- סדר התדרים ב-DFT
- הזזה מעגלית
- קונבולוציה סירקולרית
- ריפוד באפסים


```
import numpy as np
import scipy.fft as fft
import matplotlib.pyplot as plt
```

נזכיר את המשוואות המרכזיות שלנו:

$$x_n = \frac{1}{N}\sum_{k=0}^{N-1}\tilde{X}_k e^{i\frac{2\pi n}{N}k} \leftrightarrows \tilde{X}_k = \sum_{n=0}^{N-1}x_n e^{-i\frac{2\pi k}{N}n}$$

נשכח להמשך הדיון מהנרמול של $\frac{1}{N}$ למרות שלפעמים הוא חשוב

בנוסף למען הנוחות נסמן את שורש היחידה מסדר N בתור $\omega = e^{-i\frac{2\pi}{N}}$

אפשר לראות כי זה פשוט מכפלה של וקטור במטריצה. נוכל להגדיר מטריצה:

$$D_{kn} = e^{-i\frac{2\pi k}{N}n} = \omega^{kn} \Rightarrow \tilde{X}_k = \sum_{n=0}^{N-1}D_{kn}x_n$$

המטריצה D היא בגודל של $D \in \mathbb{C}_{N\times N}$ וכמובן מרוכבת.

נשים לב לכמה תכונות מיוחדות:

1. המטריצה סימטרית כלומר $D = D^T$
2. המטריצה יוניטרית (צריך להוסף נירמול). כלומר: $DD^\dagger = N\cdot I_{N\times N}$

ניתן דוגמא לאיך נראית $D_4 \in \mathbb{C}_{4\times 4}$

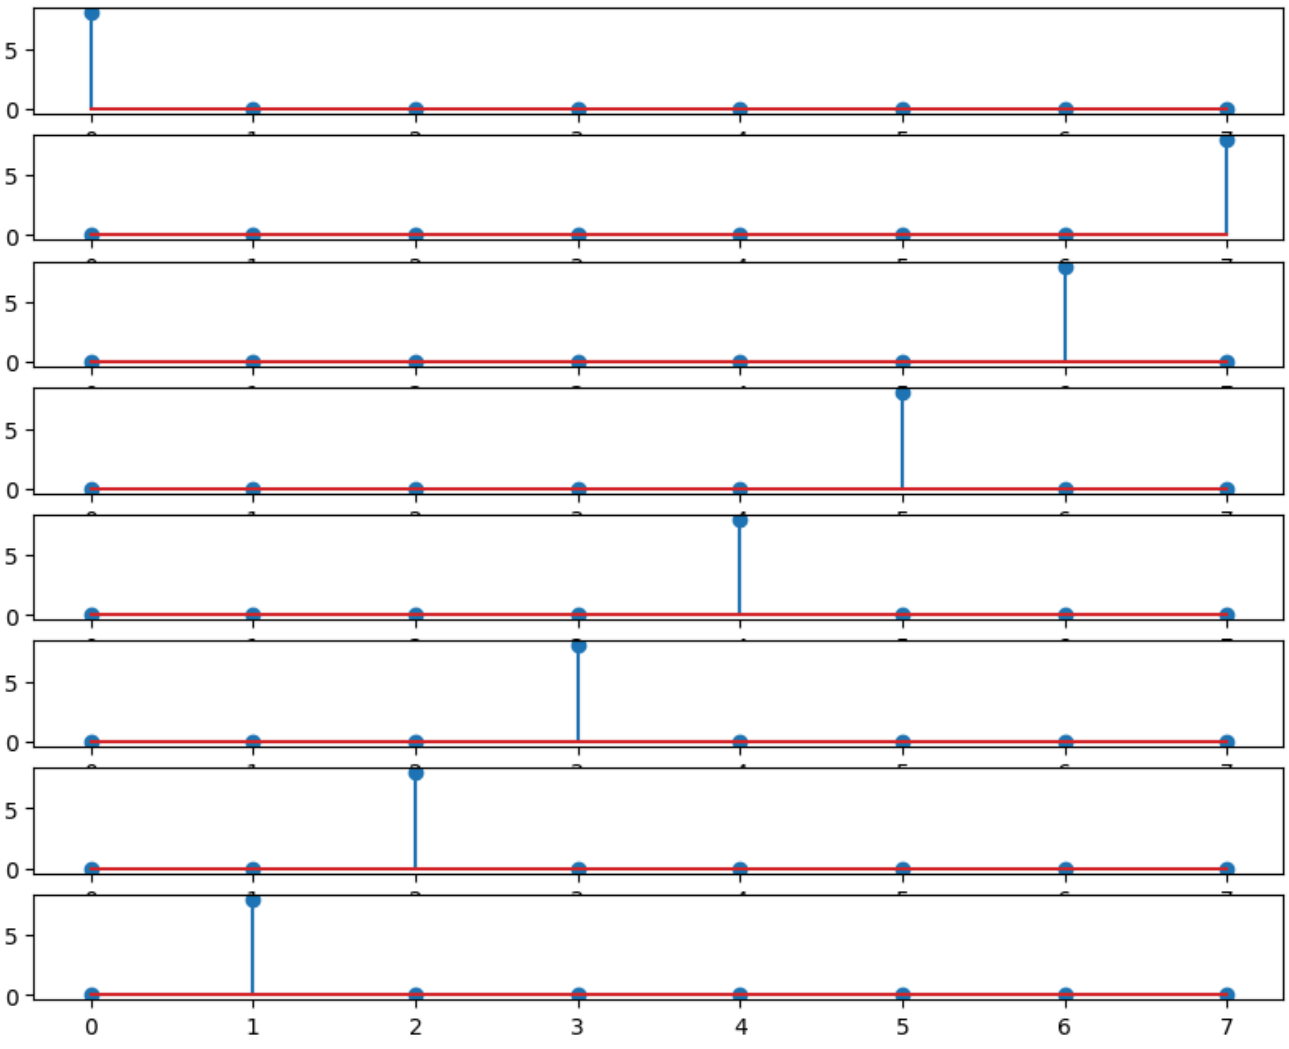
$$D_4 = \begin{pmatrix} \omega^0 & \omega^0 & \omega^0 & \omega^0 \\ \omega^0 & \omega^1 & \omega^2 & \omega^3 \\ \omega^0 & \omega^2 & \omega^4 & \omega^6 \\ \omega^0 & \omega^3 & \omega^6 & \omega^9 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & -i & -1 & i \\ 1 & -1 & 1 & -1 \\ 1 & i & -1 & -i \end{pmatrix}$$

עכשיו כשיש לנו בראש את זה שפורייה זה הכפלה במטריצה יוניטרית. נוכל לשאול את עצמנו איזה וקטורים אנחנו יכולים להכפיל במטריצה הזו ולקבל וקטור שכולו אפסים חוץ ממקום אחד. טוב כמובן מההגדרות אלו בדיוק העמודות של המטריצה. ואכן נבדוק:

```
N = 8
root_n = np.exp(-2j*np.pi/N)

D = np.array([[root_n**(k*n) for n in range(N)] for k in range(N)])

fig,axes = plt.subplots(N,1,figsize=(10,8))
# iterate over rows and calculate the dft (fft)
for i, D_k in enumerate(D):
    D_k_f = fft.fft(D_k)
    axes[i].stem(range(N),np.abs(D_k_f))
plt.show()
```



נשים לב שהעמודות הן בדיוק מה שהיינו מגדירים "תדר טהור" ומה שמיוחד בו הוא מסיים כמות סיבובים שלמה על הקטע.

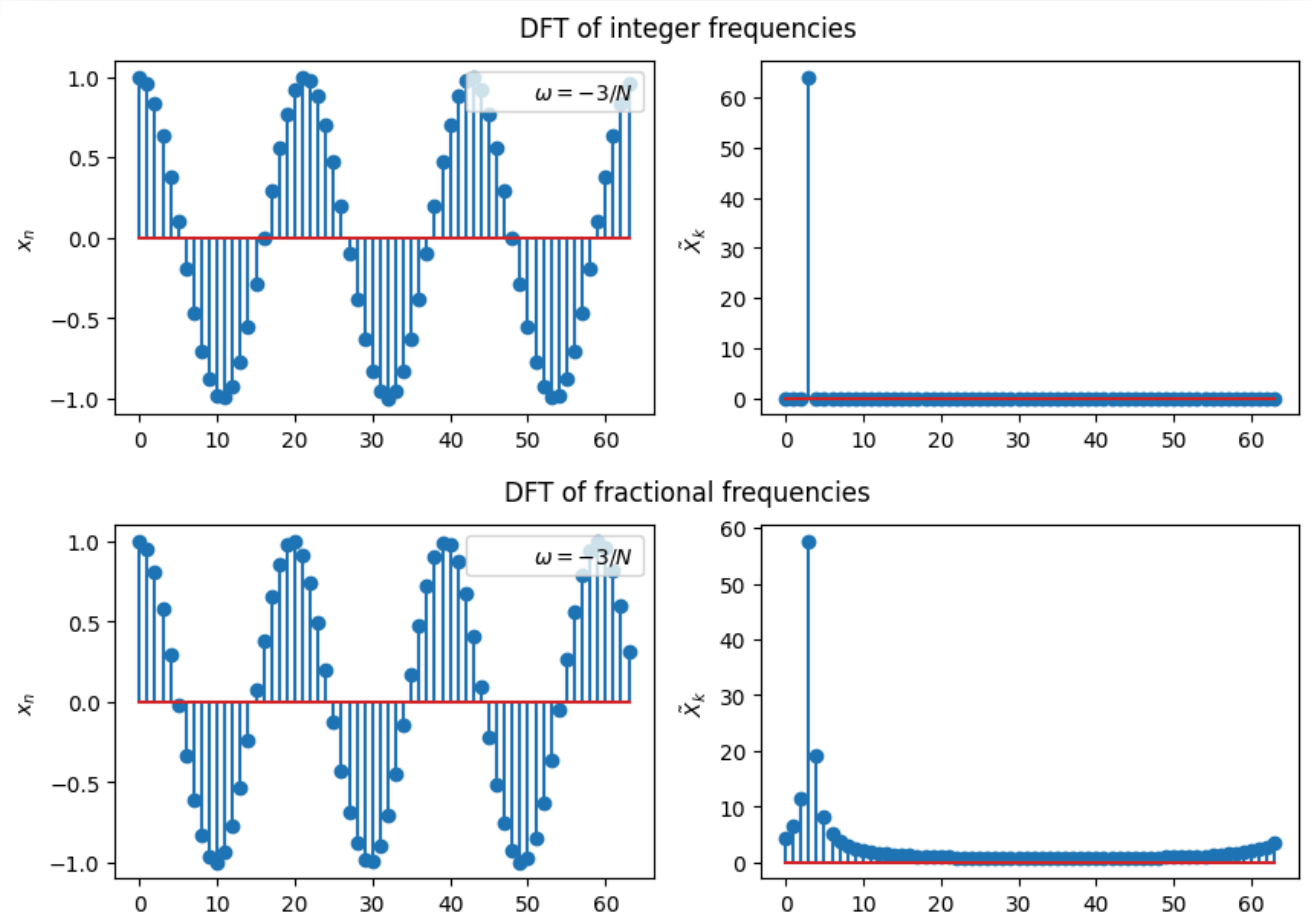
מה התדר הכי גבוה? השורה האמצעית שהיא פשוט $\begin{pmatrix} 1 \\ -1 \\ 1 \\ -1 \\ \vdots \\ -1 \end{pmatrix}$ נשים לב שזה התדר הכי גבוה רק אם N מספר זוגי.

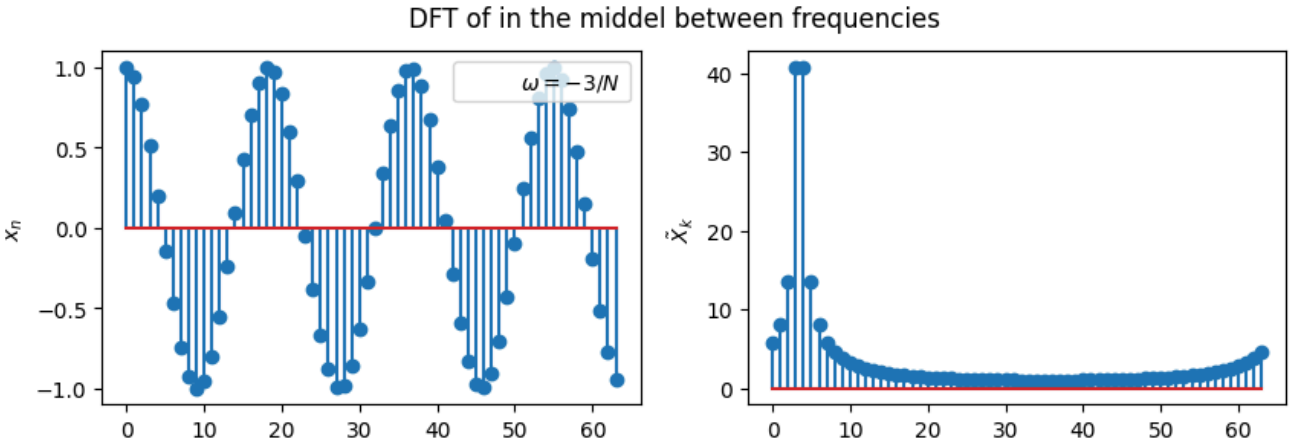
אחרת לא בדיוק מוגדר תדר הכי גבוה. כי יש לנו שתי שורות שהן "התדר הכי גבוה"

לדוגמא עבור $N = 5$ יש את העמודה שעושה קפיצות של $\frac{2}{5}$ מעגל כל פעם ויש את העמודה שעושה $\frac{3}{5}$ מעגל כל פעם.

כבר כאן אנחנו מתחילים לראות שיש חשיבות לקשר בין הדגימה הראשונה והאחרונה. מה יקרה אם ניקח תדר שגורם לכך שהגל שלנו לא יכנס מספר פעמים שלם בקטע? נבדוק:

Show code cell source





סדר התדרים ב-DFT

כבר ראינו שהתדרים (או התדר) הכי גבוהים נמצאים באמצע המטריצה. למה זה הגיוני? משום שהתדר הכי גבוה הוא לקפוץ כל פעם חצי מעגל ואחרי זה אנחנו יכולים לפרש את הקפיצות בתור קפיצות קטנות יותר לצד השני. זה אומר שהציר של התדרים הוא ממש מוזר.

הוא מתחיל מהמקדם של תדר 0 שהוא מגיע מהשורה הראשונה במטריצה. השורה הזו היא פשוט המספר 1 ולכן מחשבת ממוצע. זה תדר 0 המוכר והאהוב.

לאט לאט התדרים עולים ובשלב כלשהו אחרי התדר הגבוה ביותר התדרים נהיים שליליים.

יש פונקציה מובנית שמחזירה לנו את ציר התדר עבור חישוב פורייה מסויים.

נסתכל עליה עבור $N = 8$

```
N = 8
dt = 1 # 1/sample_rate
f_axis = fft.fftfreq(N,dt)
f_axis
```

```
array([ 0.   ,  0.125,  0.25 ,  0.375, -0.5  , -0.375, -0.25 , -0.125])
```

אבל מה אם אנחנו רוצים את כל התדרים השליליים בצד שמאל יש לזה פונקציה

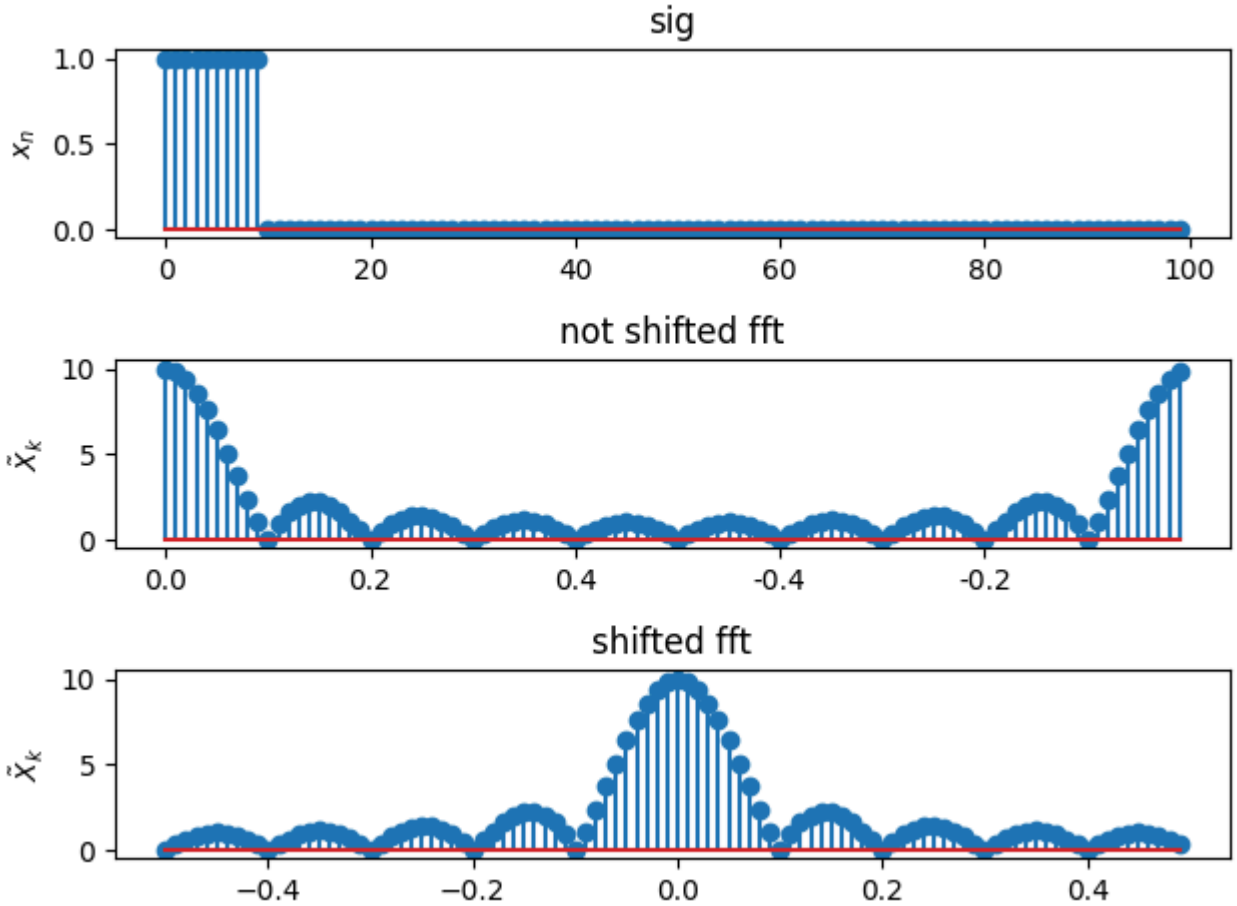
```
fft.fftshift(f_axis)
```

```
array([-0.5  , -0.375, -0.25 , -0.125,  0.   ,  0.125,  0.25 ,  0.375])
```

ולכן נניח שיש לנו סיגנל שאנחנו רוצים לעשות לו fft ולצייר אותו

```
fs = 1
sig = np.concatenate((np.ones(10),np.zeros(90)))
N = len(sig)
t_axis = np.arange(N)/fs
f_axis = fft.fftfreq(N,1/fs)
sig_f = fft.fft(sig)

fig, axes = plt.subplots(3,1)
axes[0].stem(sig)
axes[0].set_title('sig')
axes[0].set_ylabel(r'$x_{n}$')
axes[1].stem(np.abs(sig_f))
axes[1].set_xticks(np.arange(N)[::20],f_axis[::20])
axes[1].set_title('not shifted fft')
axes[1].set_ylabel(r'$\tilde{X}_{k}$')
axes[2].stem(fft.fftshift(f_axis),fft.fftshift(np.abs(sig_f)))
axes[2].set_title('shifted fft')
axes[2].set_ylabel(r'$\tilde{X}_{k}$')
fig.tight_layout()
```



הזזה מעגלית

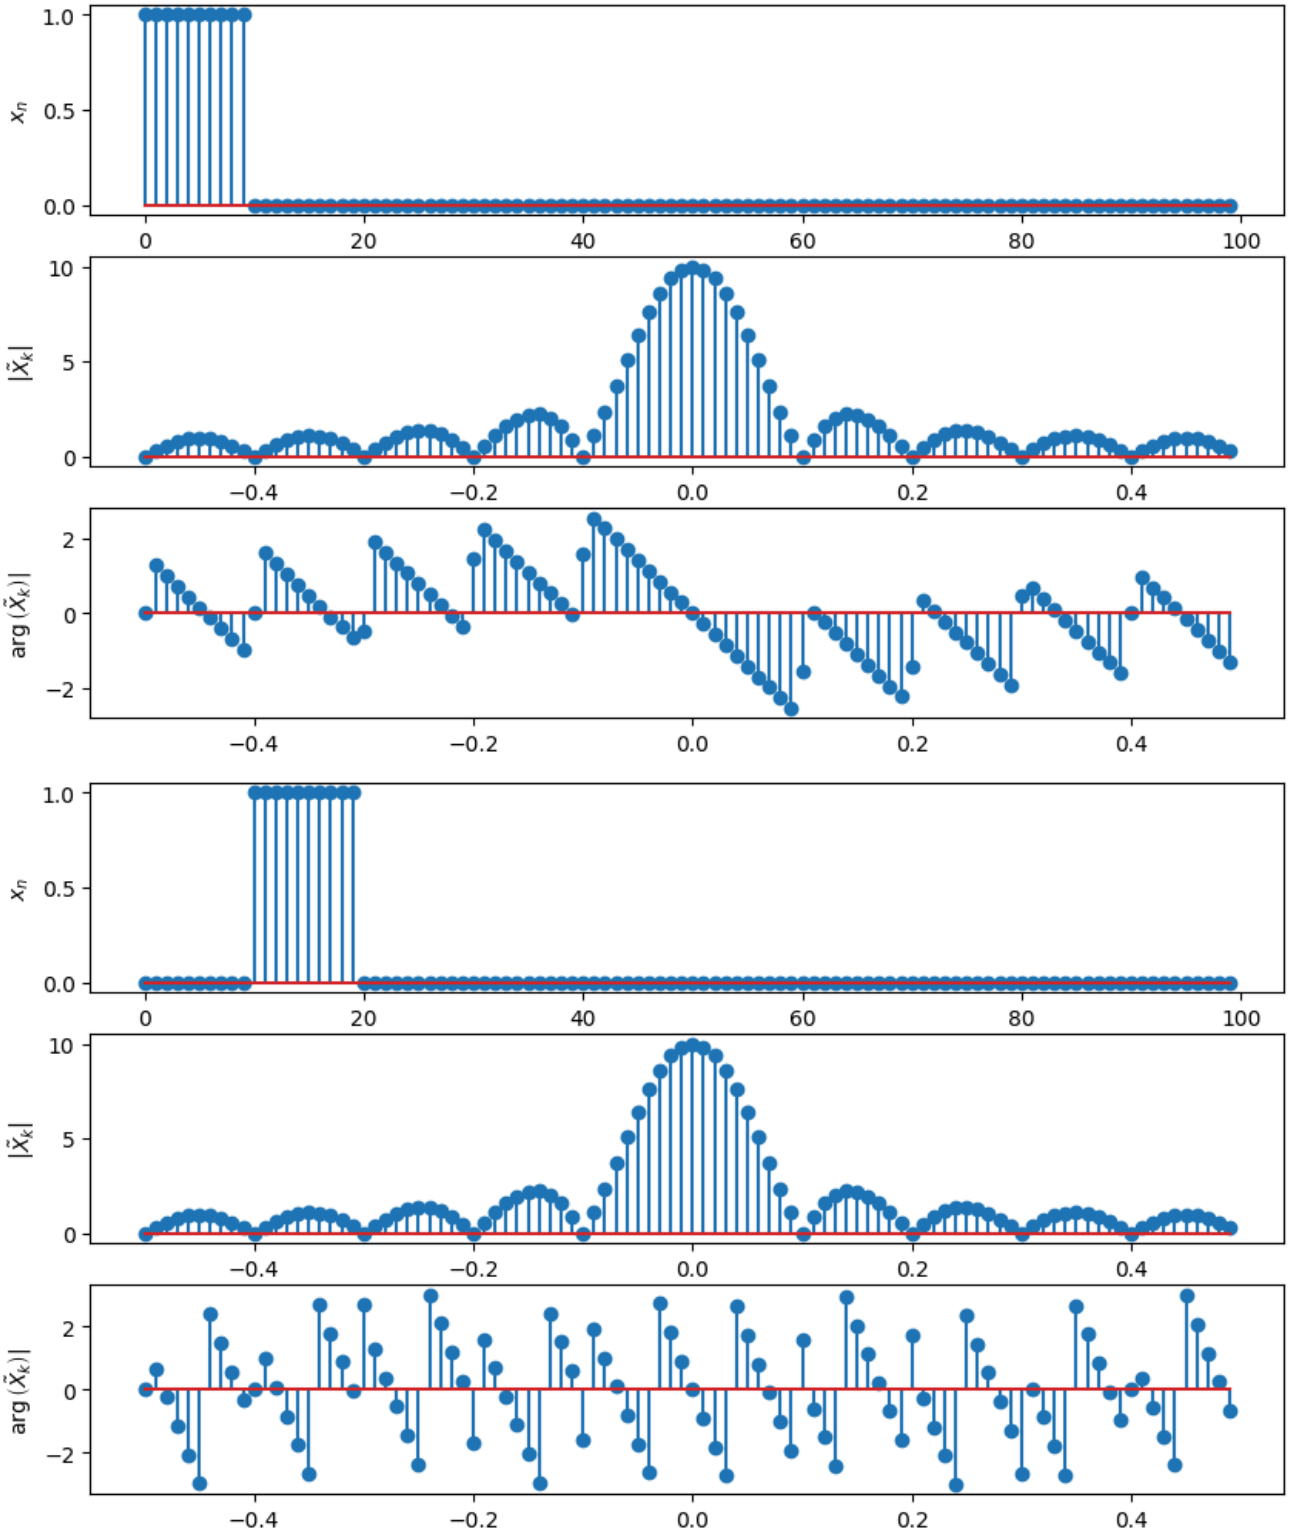
▼ Show code cell source

אנחנו יודעים שפורייה טרנספורם רציף אינווריאנטי להזזות (או יותר במדוייק מוכפל בפאזה שתלויה לינארית בתדר). מה קורה עם פורייה בדיד? מה זה בכלל אומר "להזיז" את הוקטור.

כבר קיבלנו לזה קצת רמיזות, הדגימה האחרונה והשנייה הם להסתובב על המעגל באותו קצב רק בכיוונים מנוגדים (במקרה ש-N אי זוגי) ובאופן כללי דיברנו לפני כמה שיעורים על זה שאנחנו ב-DFT מתייחסים לזמן כמעגלי. שזה אומר שאנחנו יכולים לחשוב על האות שלנו בתור רצף אינסופי של דגימות שחוזרות על עצמן במחזוריות של אורך האות שלנו N.

כלומר אנחנו רוצים לדעת מה קורה לוקטור אשר מזיזים אותו באופן מעגלי ואז עושים לו פורייה. נבדוק:

```
fs = 1
sig = np.concatenate((np.ones(10),np.zeros(90)))
fig, axes = plot_fft(sig,fs, plot_phase=True)
plt.show()
sig_roll = np.roll(sig,10)
fig, axes = plot_fft(sig_roll,fs, plot_phase=True)
plt.show()
```



קיבלנו בדיוק אותו הדבר באמפליטודה אבל הפאזה השתמנתה באופן לינארי לתדר. יחסית קל גם לראות את זה מתמטית:

$$Dx_{(n-n_0) \mod N} = \sum_{n=0}^{N-1} x_{(n-n_0) \mod N} e^{-i\frac{2\pi k}{N}n} = \sum_{n=0}^{N-1} x_{(n-n_0) \mod N} e^{-i\frac{2\pi k}{N}(n-n_0)} e^{i\frac{2\pi k}{N}n_0} = e^{i\frac{2\pi k}{N}n_0}\tilde{X}_k$$

> הזזה של וקטור דגימות בצורה **מעגלית** מייצר רק פאזה לינארית ולא משפיע על האמפליטודה של המקדמים במרחב התדר

קונבולוציה סירקולרית

נשאלת השאלה איך תראה קורלציה בין שני אותות כאלו? בבירור הסוף של אות אחד ברגע שיעבור את הסוף של אות מסויים יחזור להתחלה שלו. פעולה כזו נקראת קורלציה סירקולרית.

> קורלציה סירקולרית
>
> $$\left(\vec{x} \circledast \vec{y}\right)[m] = \sum_{n=0}^{N-1} x[n] \cdot y[(m-n) \mod N]$$

ניתן להראות מקבליה למשפט הקונבולוציה אבל הפעם לאותות סופיים

משפט הקונבולוציה לאותות סופיים

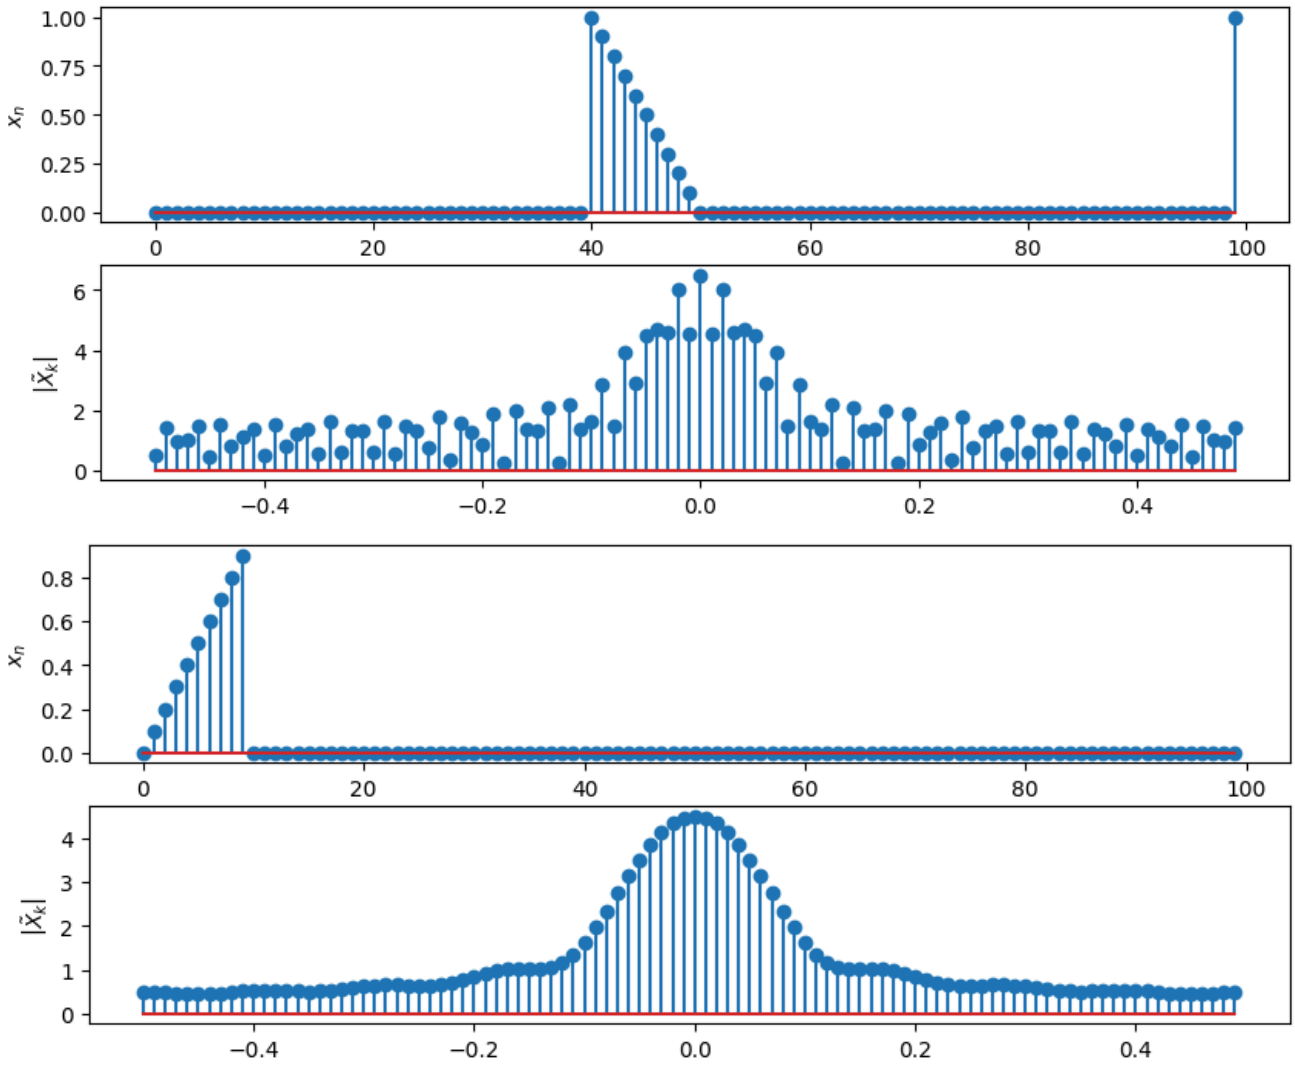
$$D\left(\vec{x} \circledast \vec{y}\right)[k] = \underbrace{\tilde{X}[k]}_{D\vec{x}} \cdot \underbrace{\tilde{Y}[k]}_{D\vec{y}}$$

בואו נראה איך זה נראה בפועל

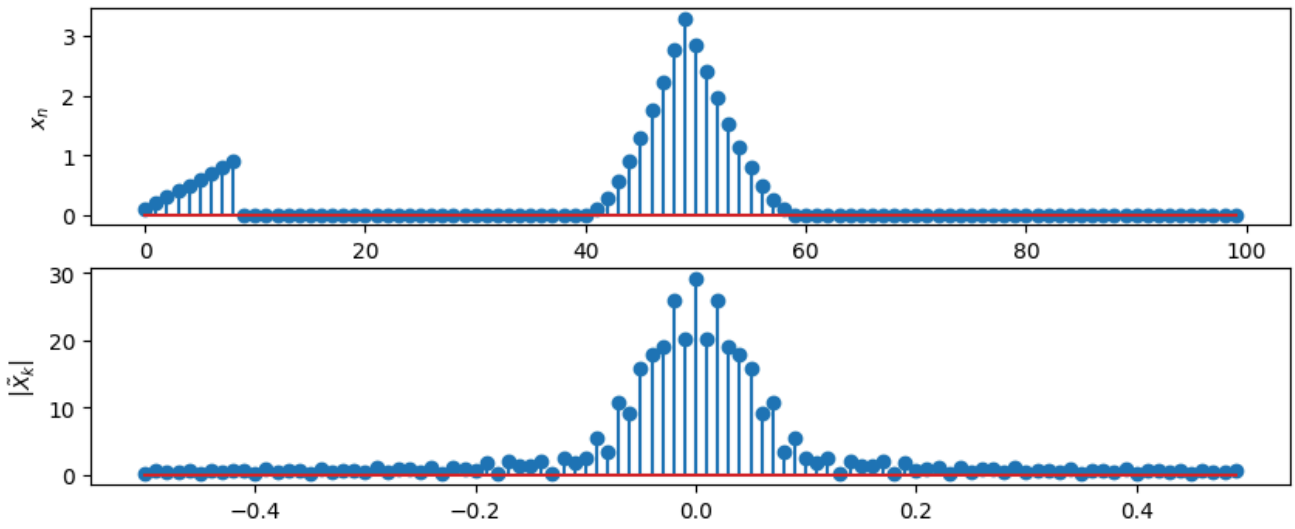
```
def circular_conv(x,y):
    x_f = fft.fft(x)
    y_f = fft.fft(y)
    return fft.ifft(x_f*y_f)
```

```
fs = 1
sig1 = np.concatenate((np.zeros(40),np.arange(10,0,-1)/10,np.zeros(49),np.ones(1)))
sig2 = np.concatenate((np.arange(10)/10,np.zeros(90)))
fig, axes = plot_fft(sig1,fs)
plt.show()
fig, axes = plot_fft(sig2,fs)
plt.show()

sig_conv = circular_conv(sig1,sig2)
fig, axes = plot_fft(sig_conv,fs)
plt.show()
```




```
py:1719: ComplexWarning: Casting complex values to real discards the imaginary part
                                                    return math.isfinite(val)
py:3463: ComplexWarning: Casting complex values to real discards the imaginary part
                                                        data[indx] = dval_
py:1355: ComplexWarning: Casting complex values to real discards the imaginary part
                                                  return np.asarray(x, float)
```



בואות נראה איך זה נראה בפועל

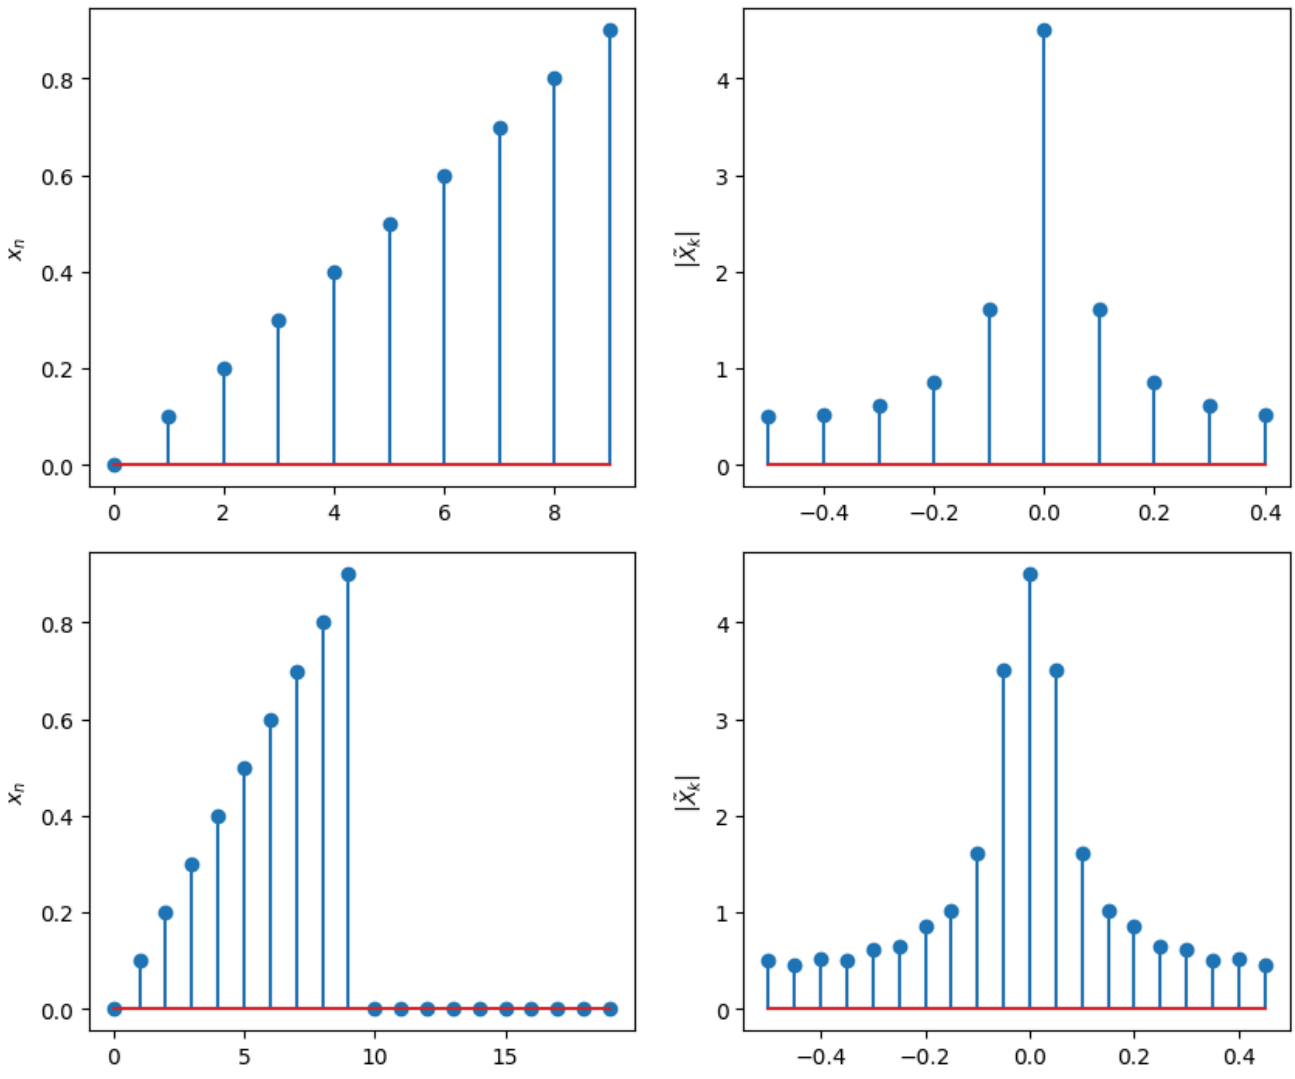
מה אנחנו רואים כאן? אנחנו יכולים לראות שקיבלנו באמת קונבולוציה כמו שהיינו מצפים משתי ראמפות אבל נשים לב שה-"דלתא" בסוף הסיגנל הראשון גרמה ל-"זליגה" לתוך ההתחלה של הקורלציה!

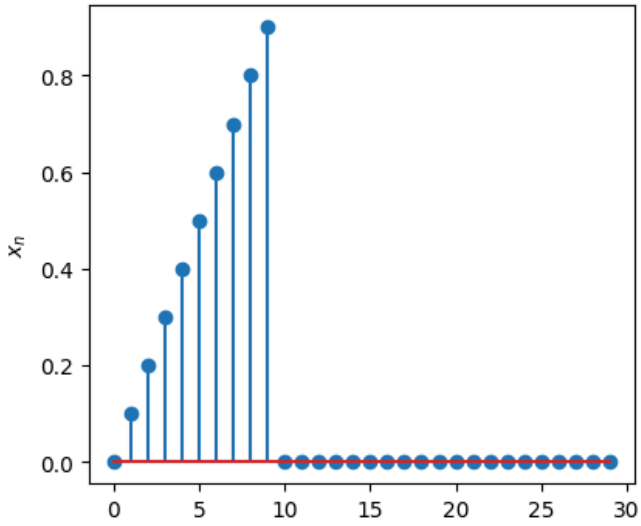
איך אפשר להתמודד עם זה? ובכן צריך לרפד באפסים

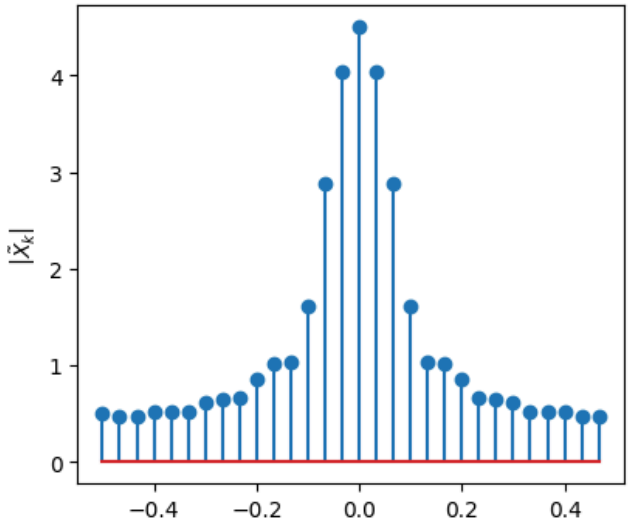
ריפוד באפסים

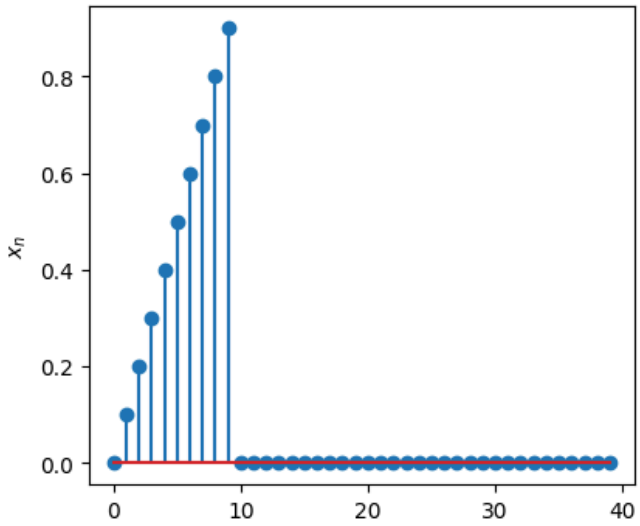
לריפוד באפסים יש כמה תפקידים חשובים בעיבוד אות דיגיטלי. ראינו את אחד מהם לפני רגע עם הקונבולוציה. אבל האמת שלריפוד אפסים יש אינטרפטציה מעניינת יותר. בואו ניקח אות ונרפד אותו לאט לאט באפסים ונצייר את ה-DFT שלו כל פעם

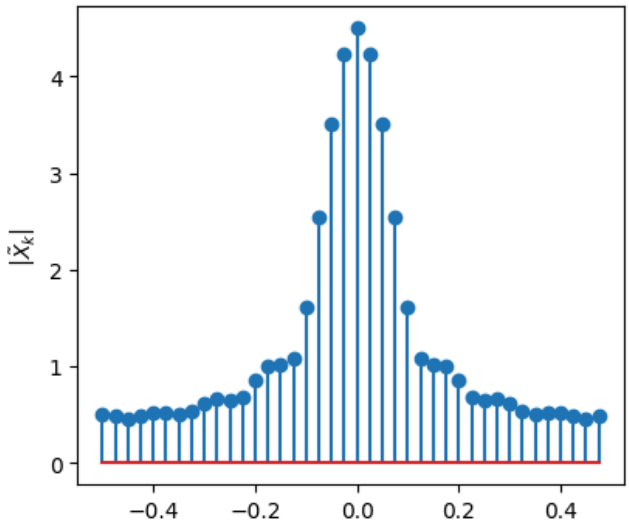
```
fs = 1
sig = np.arange(10)/10
for pad_size in np.arange(0,100,10):
    sig_pad = np.pad(sig,(0,pad_size))
    fig, axes = plot_fft(sig_pad,fs,vertical=False)
plt.show()
```

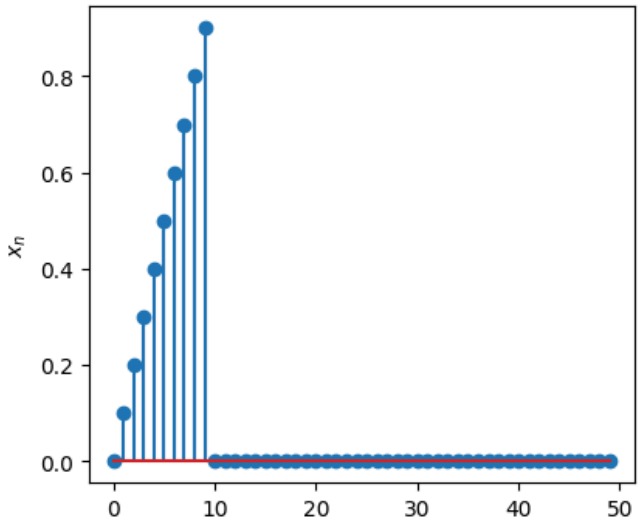


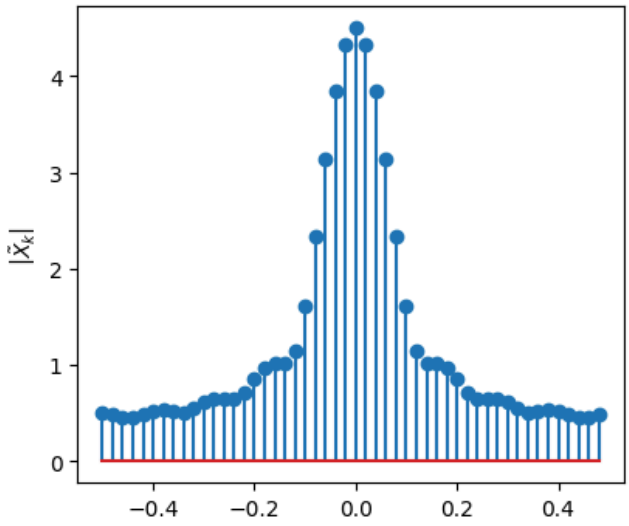

x_n
0.0
0.2
0.4
0.6
0.8
0
5
10
15
20
25
30

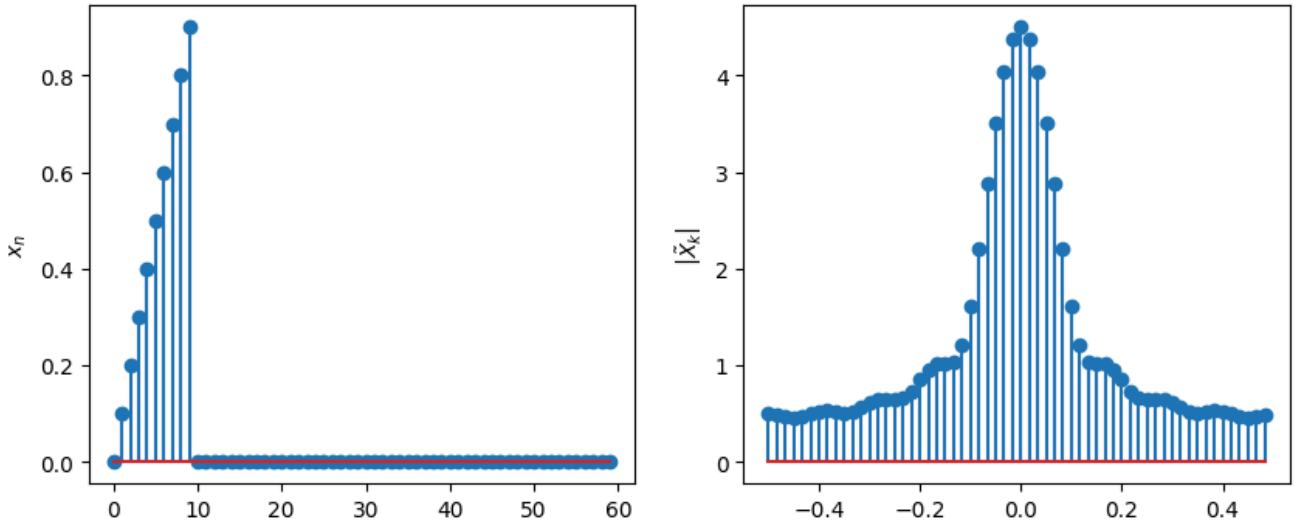

$|\tilde{X}_k|$
0
1
2
3
4
−0.4
−0.2
0.0
0.2
0.4

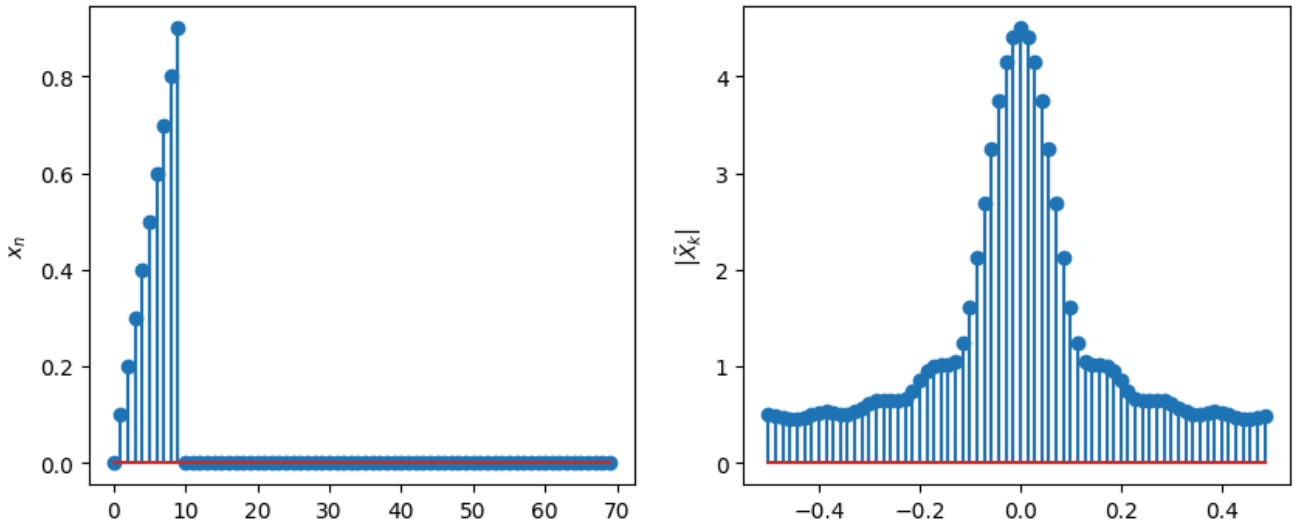

x_n
0.0
0.2
0.4
0.6
0.8
0
10
20
30
40

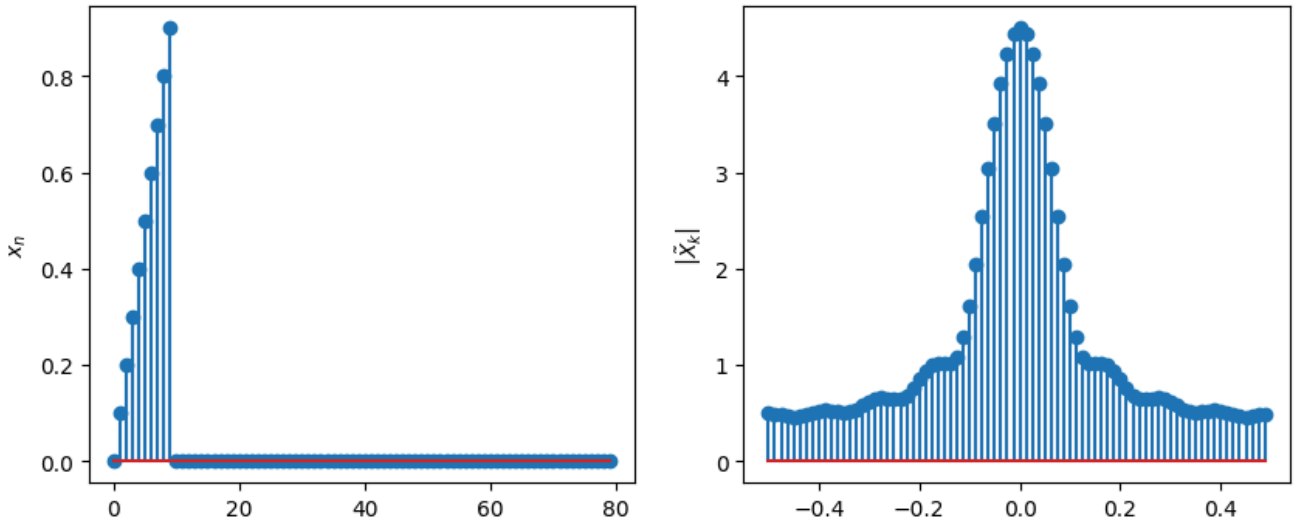

$|\tilde{X}_k|$
0
1
2
3
4
−0.4
−0.2
0.0
0.2
0.4

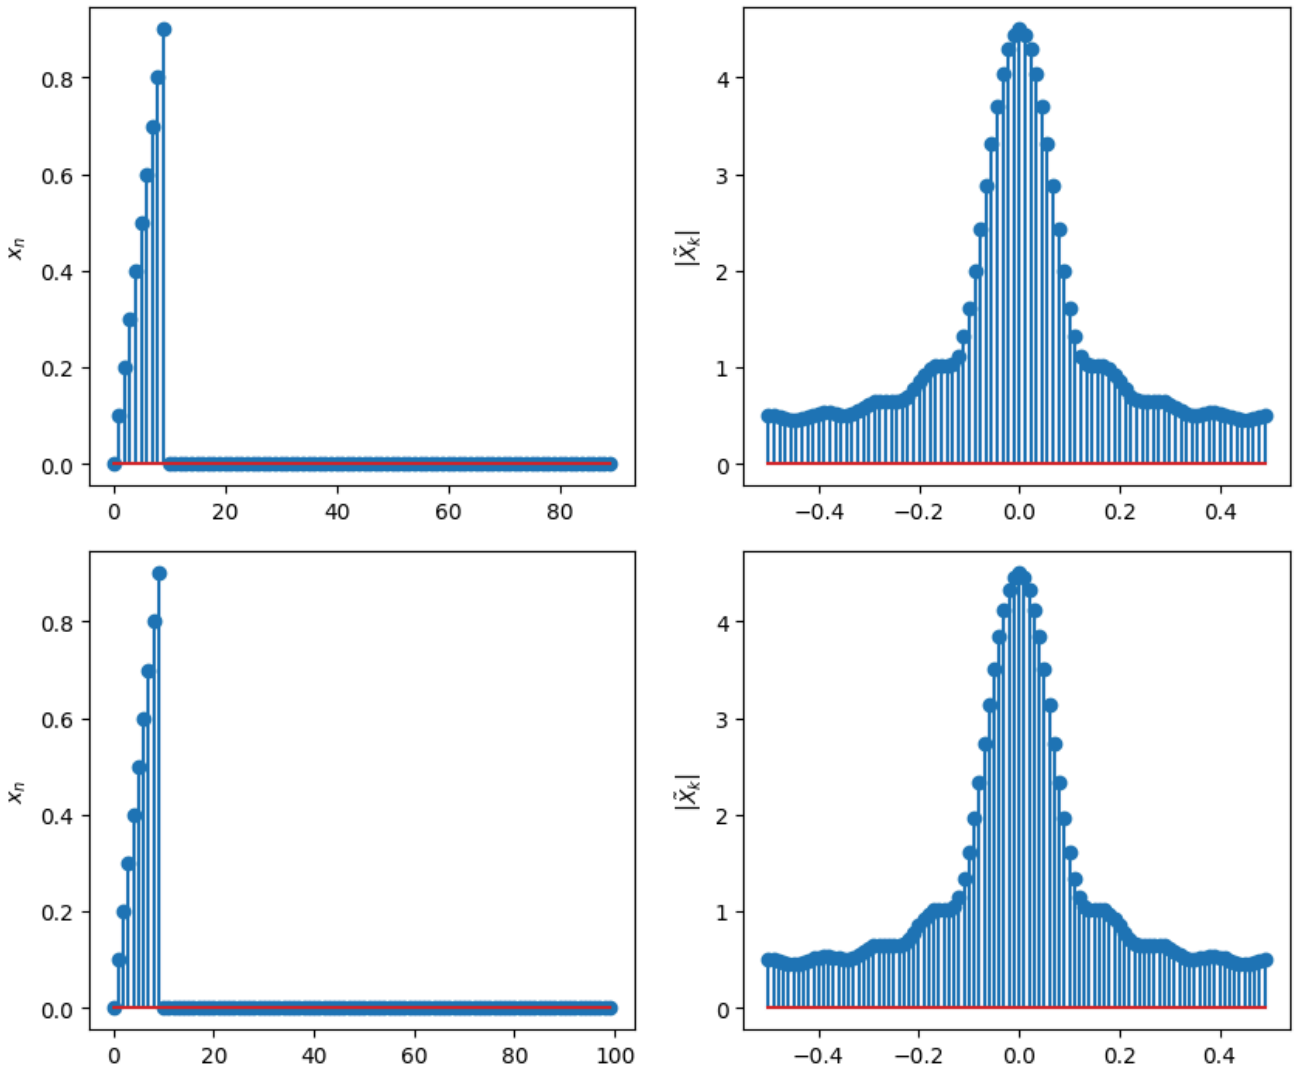

x_n
0.0
0.2
0.4
0.6
0.8
0
10
20
30
40
50


$|\tilde{X}_k|$
0
1
2
3
4
−0.4
−0.2
0.0
0.2
0.4


x_n
$|\tilde{X}_k|$

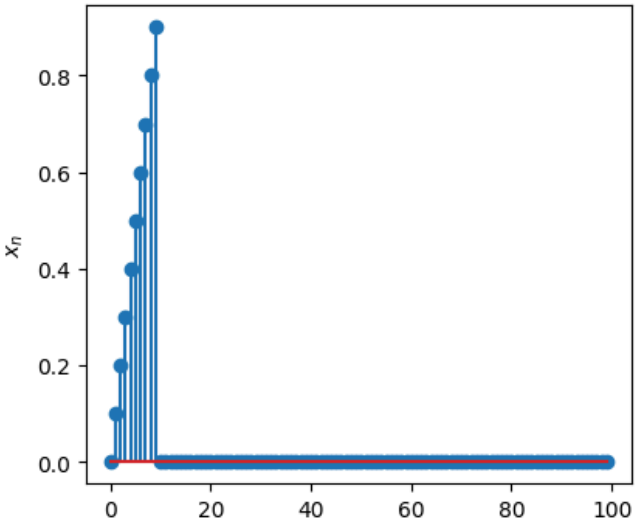

x_n
$|\tilde{X}_k|$

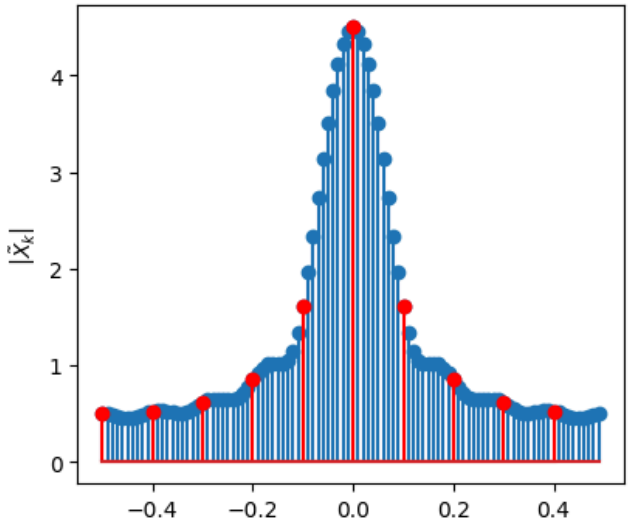

x_n
$|\tilde{X}_k|$



נשים את הסיגנל בלי הריפוד ועם הריפוד אחד על השני בתדר

```
fs = 1
sig = np.arange(10)/10
pad_size = 90
sig_pad = np.pad(sig,(0,pad_size))
fig, axes = plot_fft(sig_pad,fs,vertical=False)
f_axis = fft.fftshift(fft.fftfreq(len(sig),1/fs))
sig_f = fft.fftshift(fft.fft(sig))
axes[1].stem(f_axis,np.abs(sig_f),linefmt='red')
plt.show()
```





אנחנו רואים שככל שאנחנו מוסיפים אפסים בזמן אנחנו בעצם מקבלים רזולוציה תדרית גבוהה יותר על פונקציה רציפה כלשהי. מה היא הפונקציה הזו? אם תחזרו אחורה בשיעורים תגלו שזו הייתה בדיוק ההגדרה של הפונקציה

$$\tilde{V}(\theta) = \frac{1}{\sqrt{2\pi}} \sum_{n=-\infty}^{\infty} V_n e^{-i\theta n}$$

נקודה למחשבה. מה היה קורה אם היינו מרפדים באפסים בתדר ואז מחזירים לזמן?